สมาคมส่งเสริมเทคโนโลยี (ไทย-ญี่ปุ่น)
Technology Promotion Association (Thailand-Japan)

สถาบันเทคโนโลยีไทย-ญี่ปุ่น
Thai-Nichi Institute of Technology
泰日工業大学

AI (Artificial Intelligence)

AI

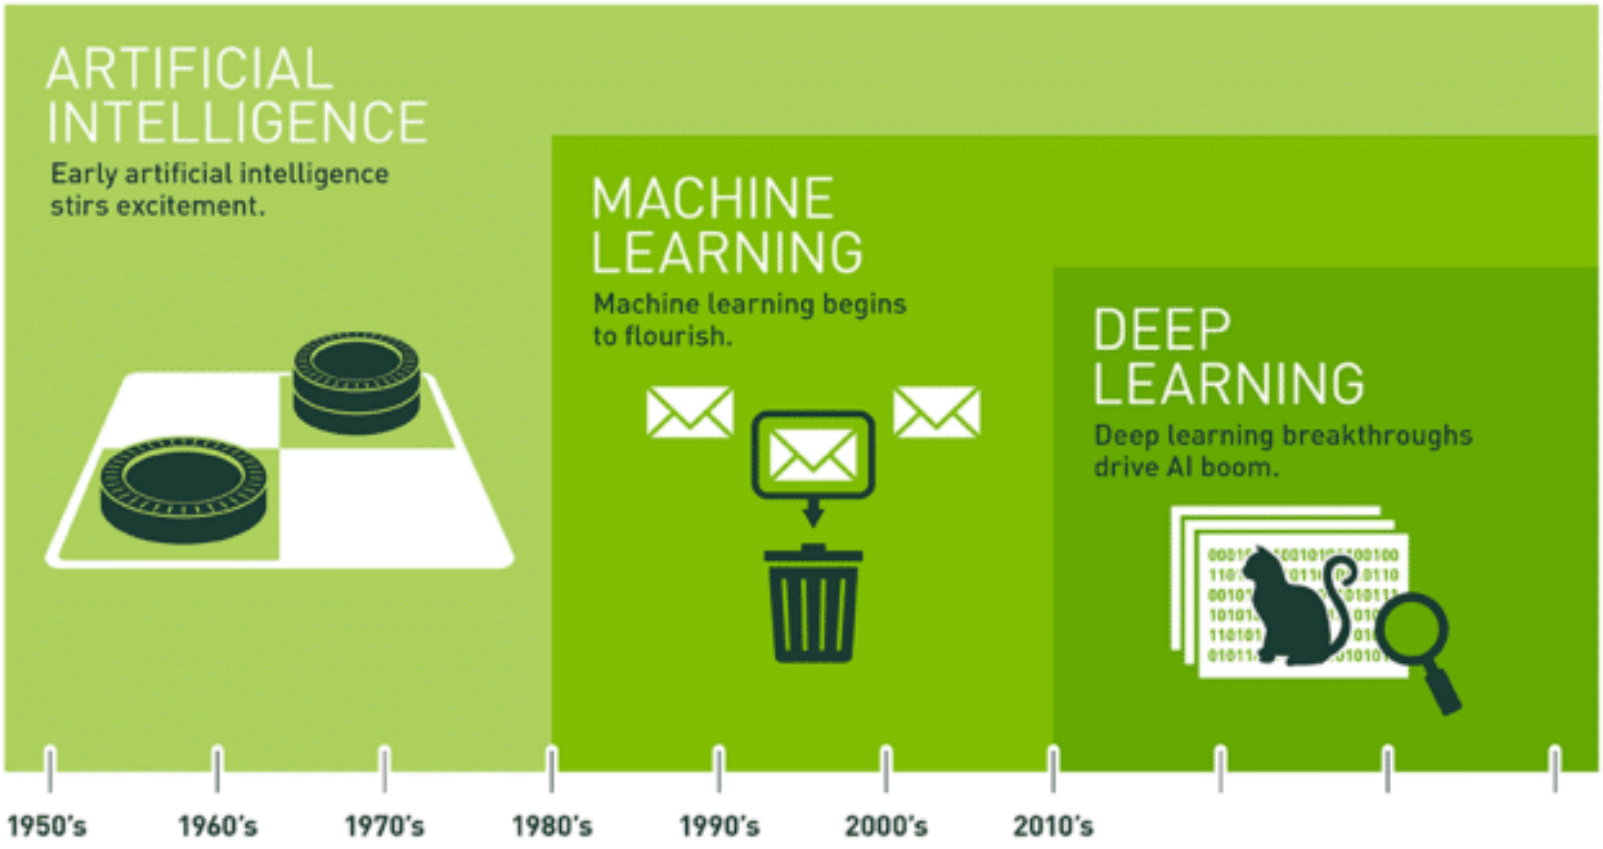

Since an early flush of optimism in the 1950s, smaller subsets of artificial intelligence – first machine learning, then deep learning, a subset of machine learning – have created ever larger disruptions.

AI

- AI ย่อมาจาก Artificial Intelligence โดยสามารถแปลเป็นภาษาได้ว่า ปัญญาประดิษฐ์ เทคโนโลยีที่สามารถบริหารจัดการข้อมูลมหาศาล ทำการประเมินผล วิเคราะห์ข้อมูลต่างๆ จนกลายเป็นเครื่องมือสำหรับการใช้งานที่มีประสิทธิภาพมากที่สุด ที่พร้อมพัฒนาตนเองอยู่เสมอ
- เริ่มใช้งานระบบปัญญาประดิษฐ์ ได้มีการสร้างขึ้นครั้งแรกเมื่อช่วงปี ค.ศ. 1956 โดยนักวิทยาศาสตร์คอมพิวเตอร์จากสหรัฐอเมริกา มีชื่อว่า John McCarthy ที่ได้พัฒนาจนสามารถสร้างเครื่องจักรที่มีความชาญฉลาดและแนวคิดแบบมนุษย์ได้เป็นเครื่องแรกนั่นเอง

Machine Learning

- Machine Learning คือ การทำให้ระบบคอมพิวเตอร์สามารถประมวลผล คาดการณ์ ตัดสินปัญหาต่างๆ ด้วยตนเองผ่านการเรียนรู้ชุดข้อมูลที่ป้อนเข้าไป
- ตัวอย่างเกี่ยวกับอัลกิริทึมของ Machine Learning ที่พบเห็นได้ในชีวิตประจำวัน ก็คือแพลตฟอร์มสตรีมเพลงต่างๆ ที่มักจะแนะนำเพลงใหม่ๆ หรือศิลปินให้กับผู้ใช้ โดยอัลกอริทึมของ Machine Learning จะทำการวิเคราะห์จากข้อมูลเพลงหรือศิลปินที่ผู้ใช้ชื่นชอบ เทียบกับผู้ฟังอื่นที่มีแนวโน้มการฟังเพลงแบบเดียวกัน หลายธุรกิจที่มีระบบแนะนำมักจะใช้เทคนิคนี้เช่นเดียวกัน

Machine Learning

- Machine Learning มักมาควบคู่กับระบบและการ Coding ที่สลับซับซ้อน
- “Machine Learning” ความหมายของมันก็คือบางอย่างที่แสดงผลการทำงานเดียวกับข้อมูลที่ถูกป้อน และให้ผลลัพธ์ที่ดีขึ้นเรื่อย ๆ เมื่อเวลาผ่านไป เหมือนกับคุณมีไฟฉายที่มักเปิดเองอัตโนมัติเมื่อคุณพูดประมาณว่า “ที่นี่มืดจังเลยนะ” ต่อให้คุณไม่ได้พูดประโยคเดียวกันนี้ ไฟฉายนั้นก็จะยังคงเปิดเอง

Deep learning

- Deep Learning คือ การจำลองระบบการประมวลผลของเซลล์ประสาทและสมองของมนุษย์ กล่าวได้ว่าเป็นการเลียนแบบการทำงานของระบบสมองมนุษย์
- การทำงานของ Deep Learning จะใช้โครงสร้างที่เหมือนกับเซลล์ประสาทในสมองของมนุษย์มาประเมินผลเพื่อให้ผลลัพธ์ที่ต้องการ สามารถที่จะประมวลผลได้อย่างแม่นยำ รวดเร็วและทรงพลังเป็นอย่างมาก

ChatGPT

- ChatGPT is a natural language processing tool driven by AI technology that allows you to have human-like conversations and much more with the chatbot. The language model can answer questions and assist you with tasks, such as composing emails, essays, and code.

ChatGPT

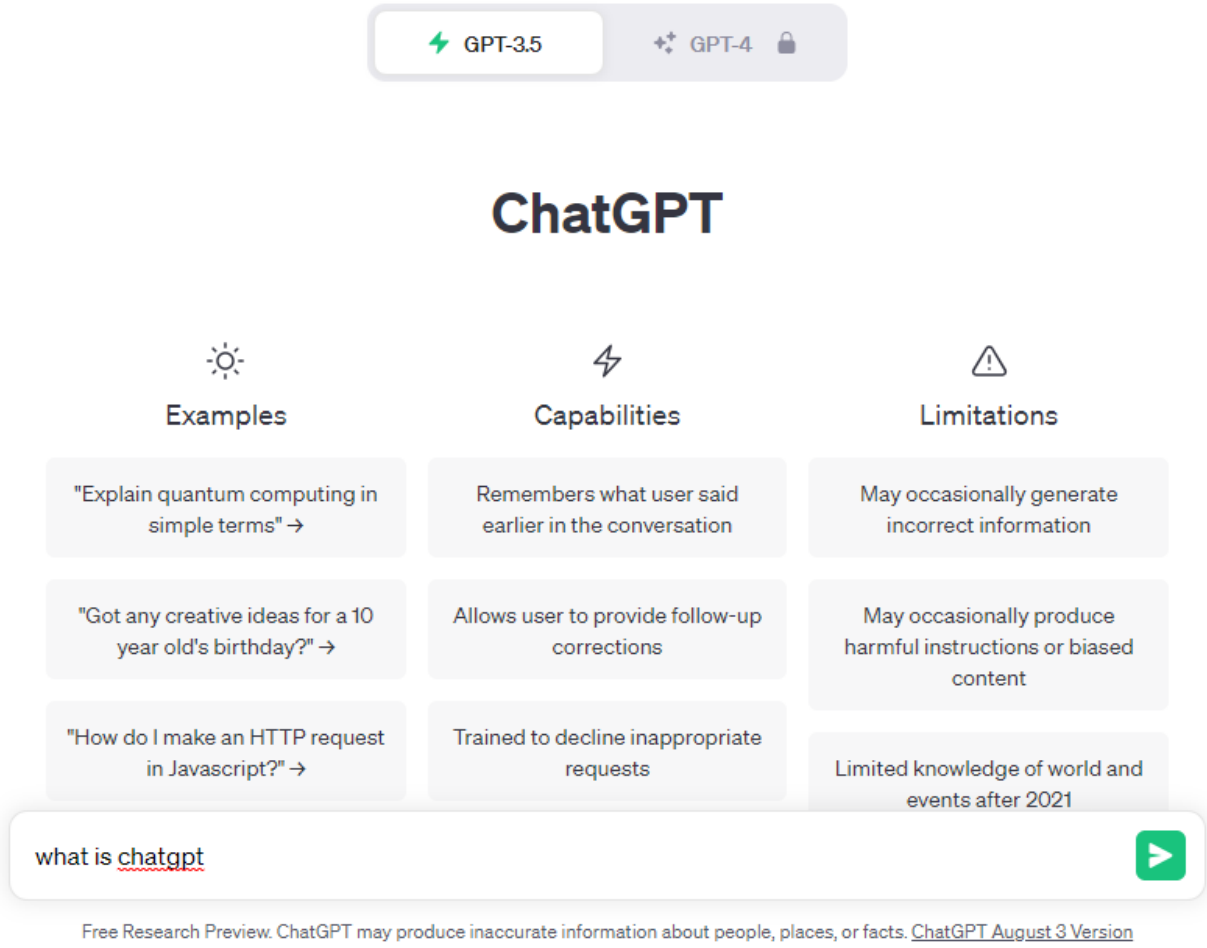

https://chat.openai.com/

Machine Learning

- Machine Learning แบ่งออกได้ 3 ประเภท
  - Supervised Learning
  - Unsupervised Learning
  - Reinforcement Learning

Supervised Learning

- Supervised Learning คือ การสร้างโมเดลเพื่อแปลงข้อมูล **input** เป็น **target** บางอย่าง ตัวอย่างง่ายที่สุดคือ **classification** กับ **regression**
- Classification คือมี **target** เป็นชนิดของข้อมูล เช่น เรียนรู้ว่า **email** เป็น **spam** หรือไม่เป็น **spam**
- Regression คือมี **target** เป็นตัวเลข เช่น เรียนรู้การประมาณราคาที่ดินจากปัจจัยแวดล้อม
- การจะสร้างโมเดลประเภทนี้ขึ้นมา ต้องมีชุดข้อมูลที่มีทั้ง **input** และ **target** ซึ่งจัดหามาโดยมนุษย์ เช่น การสร้าง **spam filter** ต้องรวมรวบข้อมูล **email** จำนวนมากและให้คนมาดูว่าอันไหนเป็น **spam** บ้าง แล้วนำมาสร้างโมเดล **spam filter** จากข้อมูลเหล่านี้

Supervised Learning

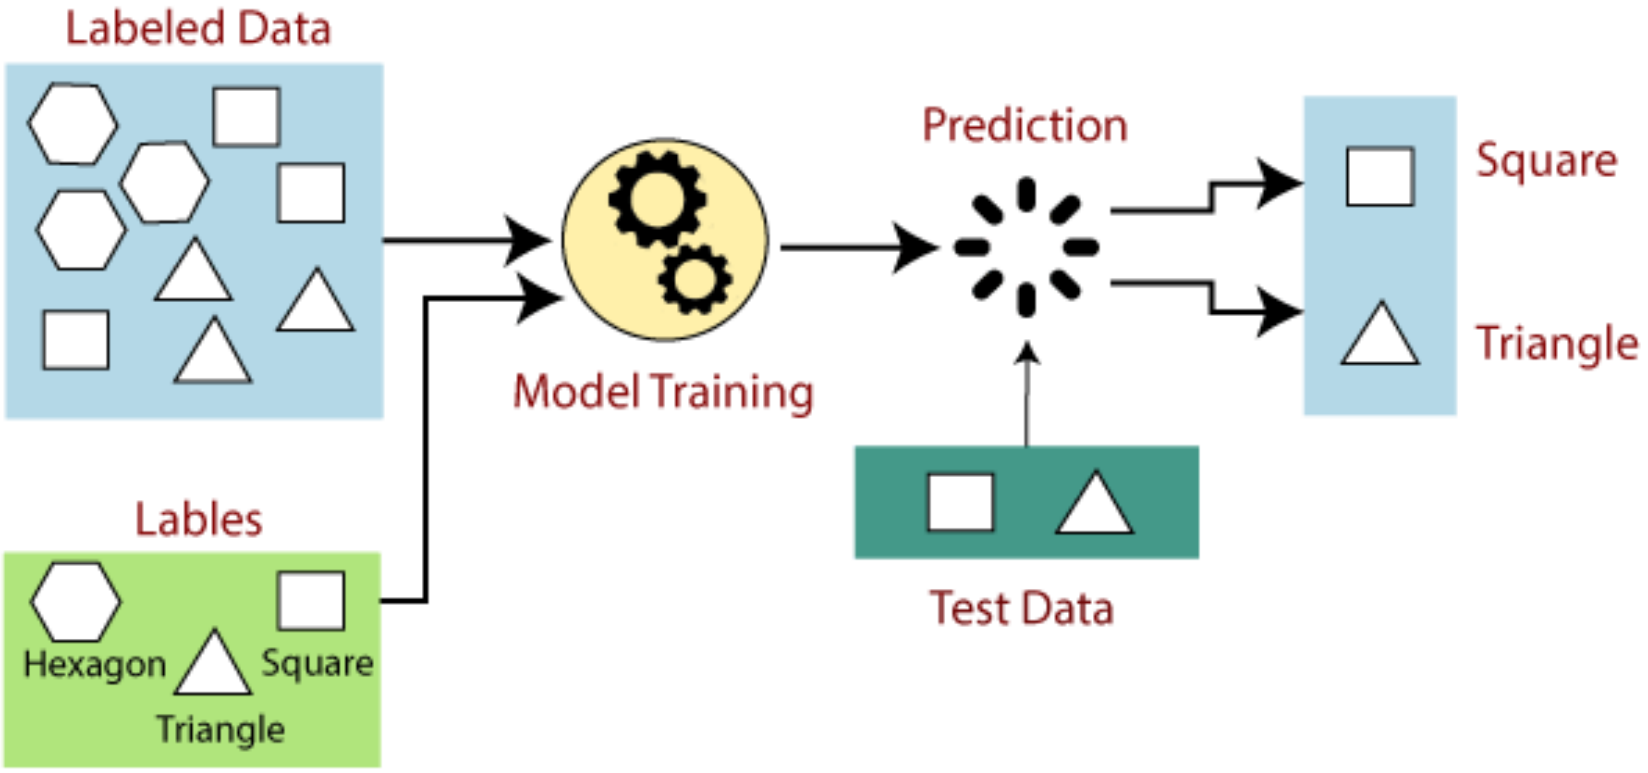

Supervised Learning

Simple Linear Regression:

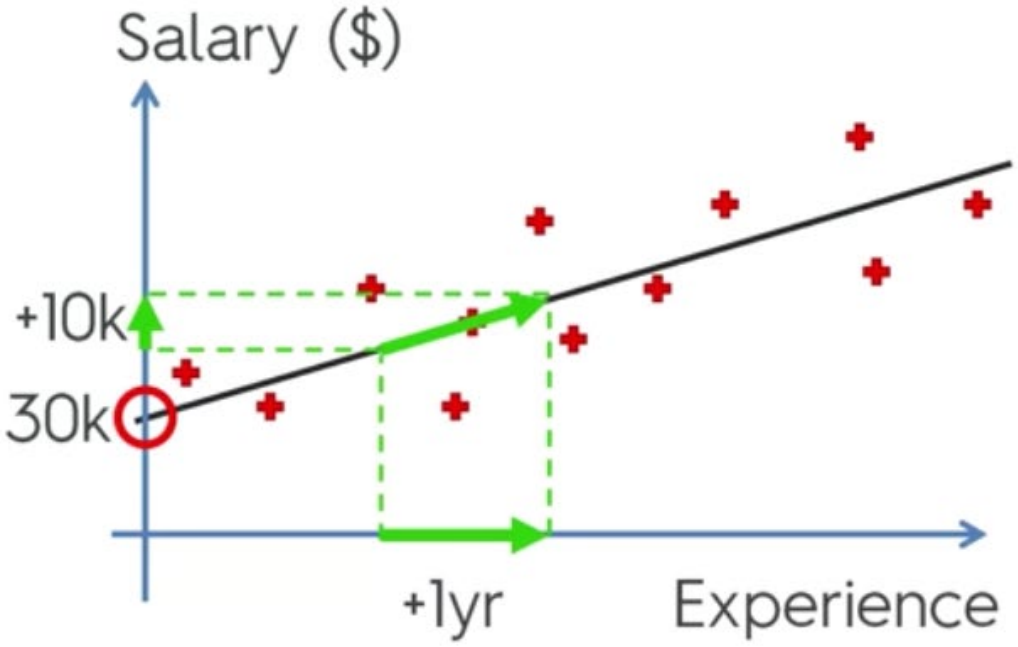

$y = b_0 + b_1 * x$

Salary = b_0 + b_1 *Experience

Unsupervised Learning

- Unsupervised Learning คือ การสร้างโมเดลโดยใช้ข้อมูล input เพียงอย่างเดียว ไม่มี target
- Clustering การจัดกลุ่มข้อมูลตามคุณลักษณะ เช่น การจัดกลุ่มลูกค้าตามพฤติกรรมการซื้อของ
- การสร้างโมเดลประเภทนี้ขึ้นมา ใช้เพียงข้อมูล input อย่างเดียว ไม่ต้องจัดหา target เช่น โมเดลการจัดกลุ่มลูกค้า เราไม่ต้องรู้มาก่อนว่าจะมีกลุ่มอะไรบ้าง

Unsupervised Learning

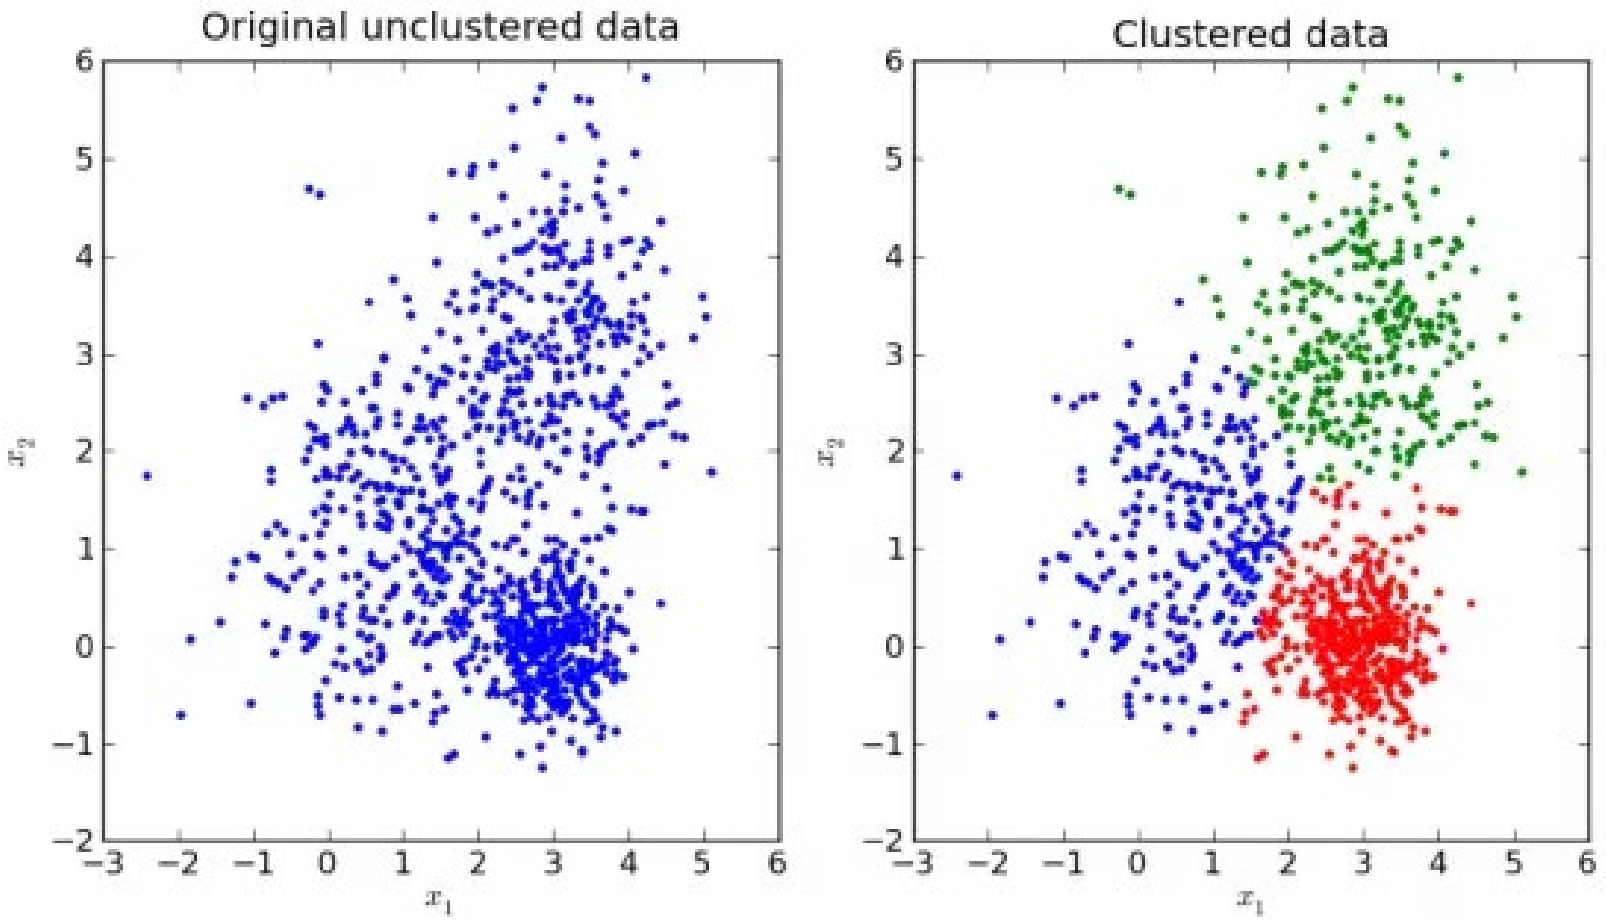

Unsupervised Learning

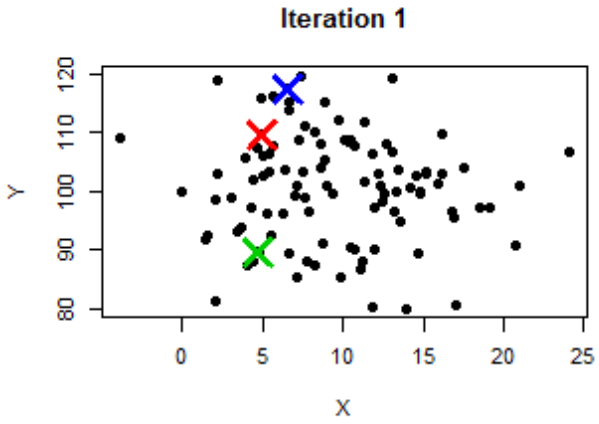

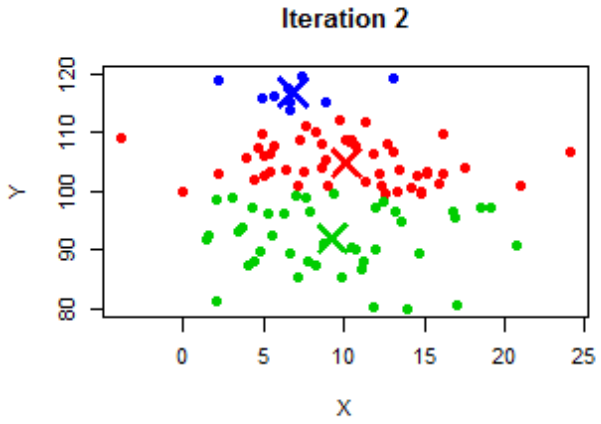

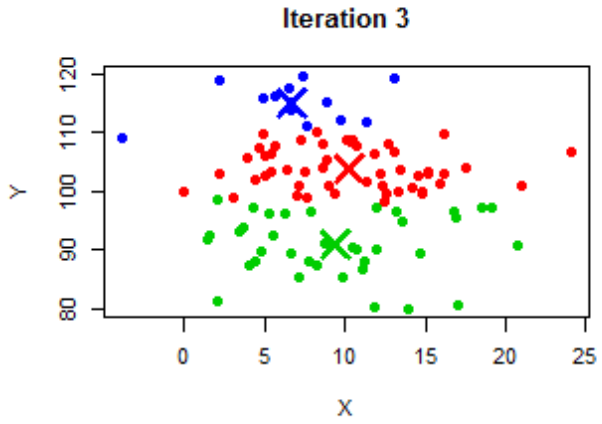

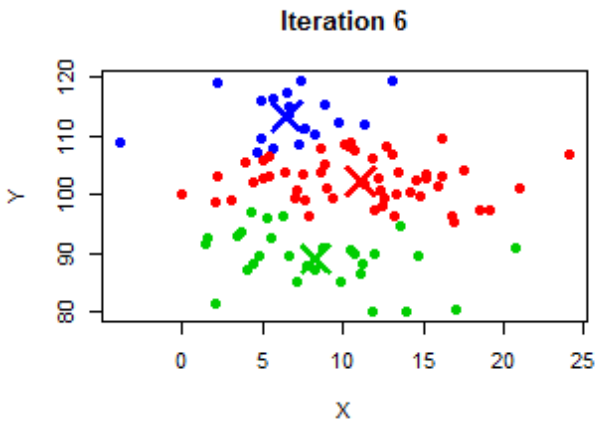

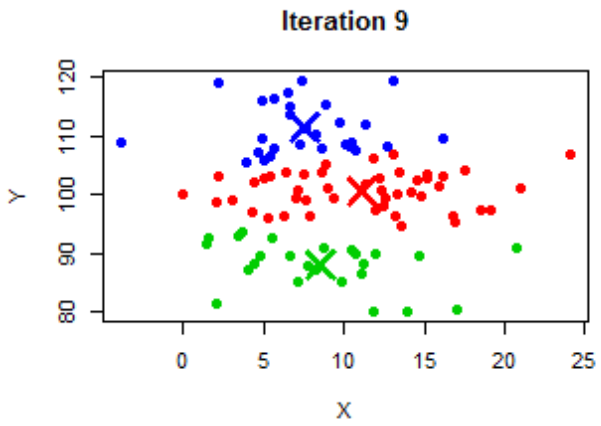

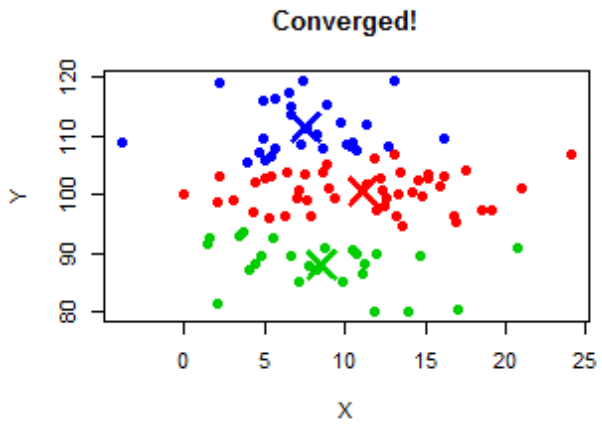

Reinforcement Learning

- Reinforcement Learning คือ การเรียนรู้แบบเสริมกำลัง ที่มีการเรียนรู้สิ่งต่าง ๆ จาก Agent (ผู้กระทำ Action) ภายใต้การเลือกกระทำสิ่งต่าง ๆ ให้ได้ผลลัพธ์ที่มากที่สุด ผ่านการลองผิดลองถูกภายใต้สถานการณ์หรือระบบจำลอง ที่พัฒนาระบบการตัดสินใจให้ดีขึ้นเรื่อย ๆ เช่น การเล่นเกมโกะให้ชนะผู้เล่นระดับโลก ไปจนถึงการพิจารณาเลือกซื้อสินทรัพย์ และการลงทุนในรูปแบบต่าง ๆ เป็นต้น

Reinforcement Learning

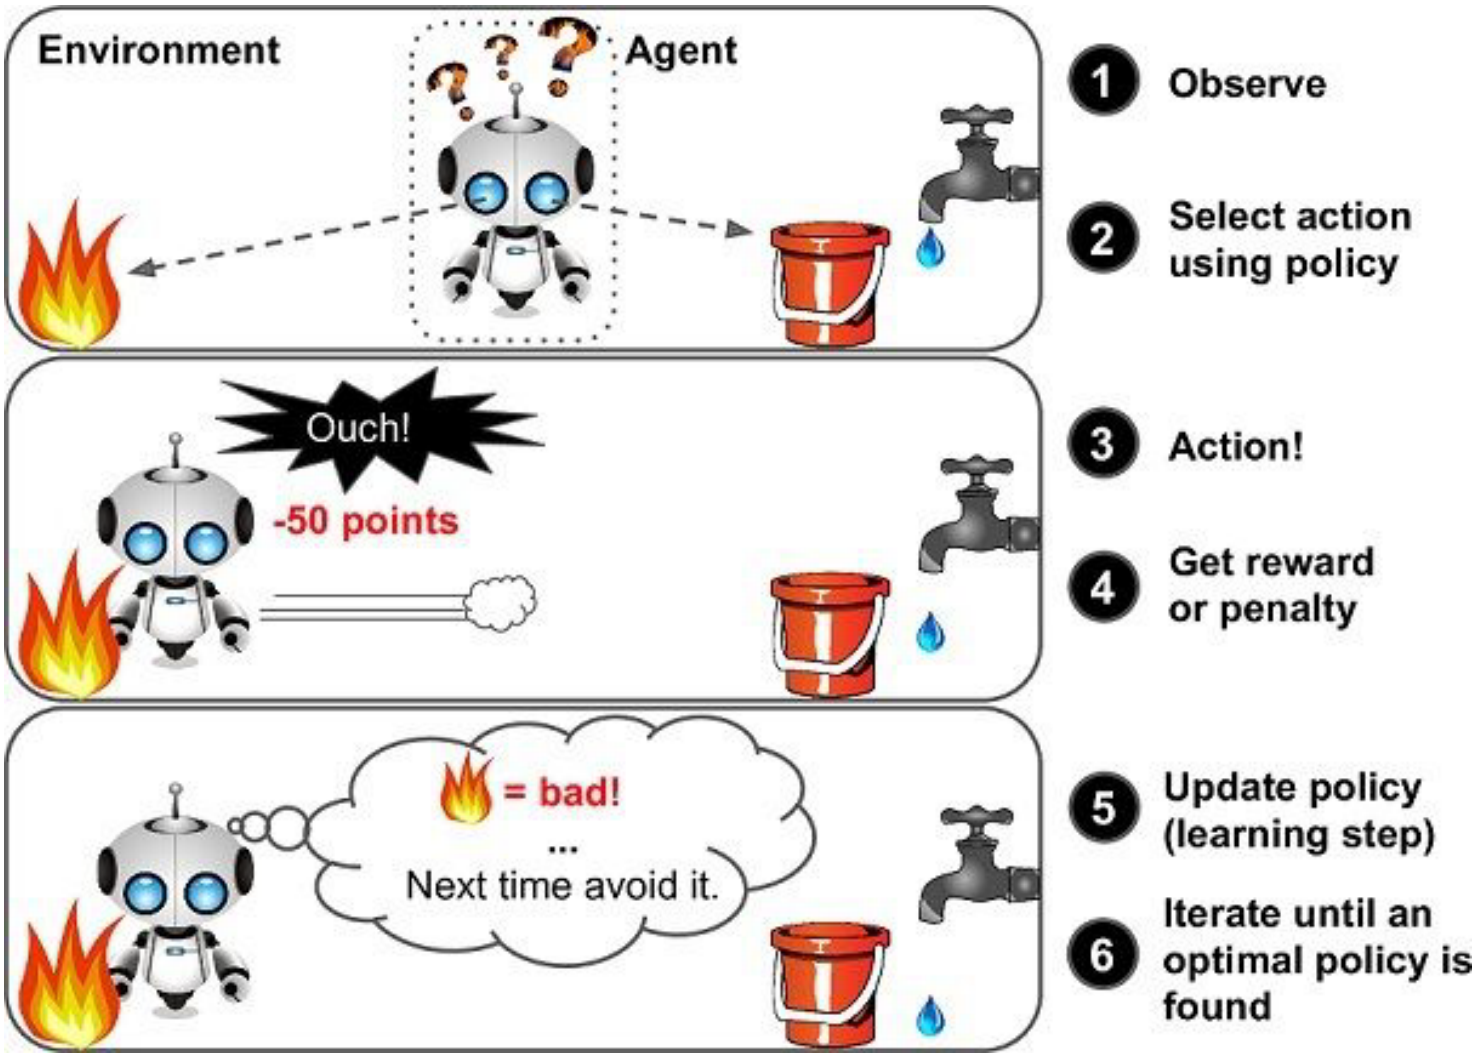

Reinforcement Learning

Reinforcement Learning

Summary [edit]

Game	Date	Black	White	Result	Moves
1	9 March 2016	Lee Sedol	**AlphaGo**	Lee Sedol resigned	186 Game 1
2	10 March 2016	**AlphaGo**	Lee Sedol	Lee Sedol resigned	211 Game 2
3	12 March 2016	Lee Sedol	**AlphaGo**	Lee Sedol resigned	176 Game 3
4	13 March 2016	AlphaGo	**Lee Sedol**	AlphaGo resigned	180 Game 4
5	15 March 2016	Lee Sedol[note 1]	**AlphaGo**	Lee Sedol resigned	280 Game 5
Result: **AlphaGo 4 – 1 Lee Sedol**					

Linear regression

Linear regression

- Linear Regression จัดอยู่ในกลุ่ม Supervised Learning
- ใช้ในการทำนายผลแบบ Regression ซึ่งเป็นการทำนายตัวเลขที่มีค่าไม่แน่นอน

Linear regression

- Linear regression คือ อัลกอริทึมหนึ่งในการวิเคราะห์สถิติและเครื่องมือทางคณิตศาสตร์ที่ใช้ในการประมาณค่าของตัวแปรตาม (dependent variable) จากตัวแปรอิสระ (independent variable) ที่เป็นเส้นตรง
- ใช้รูปแบบสมการเชิงเส้น (linear equation) เพื่อพยากรณ์หรือสร้างรูปแบบทางคณิตศาสตร์เพื่อใช้ในการคาดการณ์ผลลัพธ์ในอนาคตของข้อมูล
- ในกรณีของ linear regression แบบเดียว (simple linear regression) จะมีตัวแปรอิสระเพียงตัวเดียว

Linear regression

- เป้าหมายของ **linear regression** คือ การหาความสัมพันธ์ระหว่างตัวแปรอิสระกับตัวแปรตามแบบเชิงเส้น
- สร้างสมการเชิงเส้นที่ใช้ในการประมาณค่าตัวแปรตามโดยป้อนค่าของตัวแปรอิสระ

Linear regression

- สมการของ Linear regression สำหรับกรณีของ simple linear regression (ตัวแปรอิสระเพียงตัวเดียว) สามารถแสดงได้ดังนี้

$$y = \beta_0 + \beta_1 x$$

Linear regression

$$y = \beta_0 + \beta_1 x$$

- y คือตัวแปรตาม (**dependent variable**) ที่เราต้องการประมาณค่าหรือพยากรณ์
- x คือตัวแปรอิสระ (**independent variable**) ที่เราใช้ในการประมาณค่าหรือพยากรณ์
- β_0 และ β_1 เป็นค่าคงที่ (**coefficients**) ที่ใช้ปรับสมการให้เข้ากับข้อมูลที่มีอยู่

Linear regression

- กำหนดให้ x = [1 2 3 4 6] และ y = [5 7 9 11 15] เมื่อนำพิกัด x,y มาพล็อตกราฟ โดยใช้ ภาษา python ดังนี้

```python
import numpy as np #numpy เป็นชื่อของ library ที่ใช้ในการคำนวนทางคณิตศาสตร์
import matplotlib.pyplot as plt #matplotlib เป็นชื่อของ library ที่นิยมใช้มากที่สุดในการพลอตกราฟสองมิติจาก array

x = np.array([1, 2, 3, 4, 6])
y = np.array([5, 7, 9, 11, 15])

coefficients = np.polyfit(x, y, 1)
m = coefficients[0]  # ความชัน (slope)
b = coefficients[1]  # จุดตัดแกน y (intercept)
regression_line = m * x + b

plt.scatter(x, y, color='blue', label='Data')
plt.plot(x, regression_line, color='red', label='Linear regression')
plt.xlabel('X')
plt.ylabel('Y')
plt.title('Linear regression')
plt.legend()
plt.show()
```

Linear regression

- กำหนดให้ x = [1 2 3 4 6] และ y = [5 7 9 11 15] เมื่อนำพิกัด x,y มาพล็อตกราฟ โดยใช้ ภาษา python ดังนี้

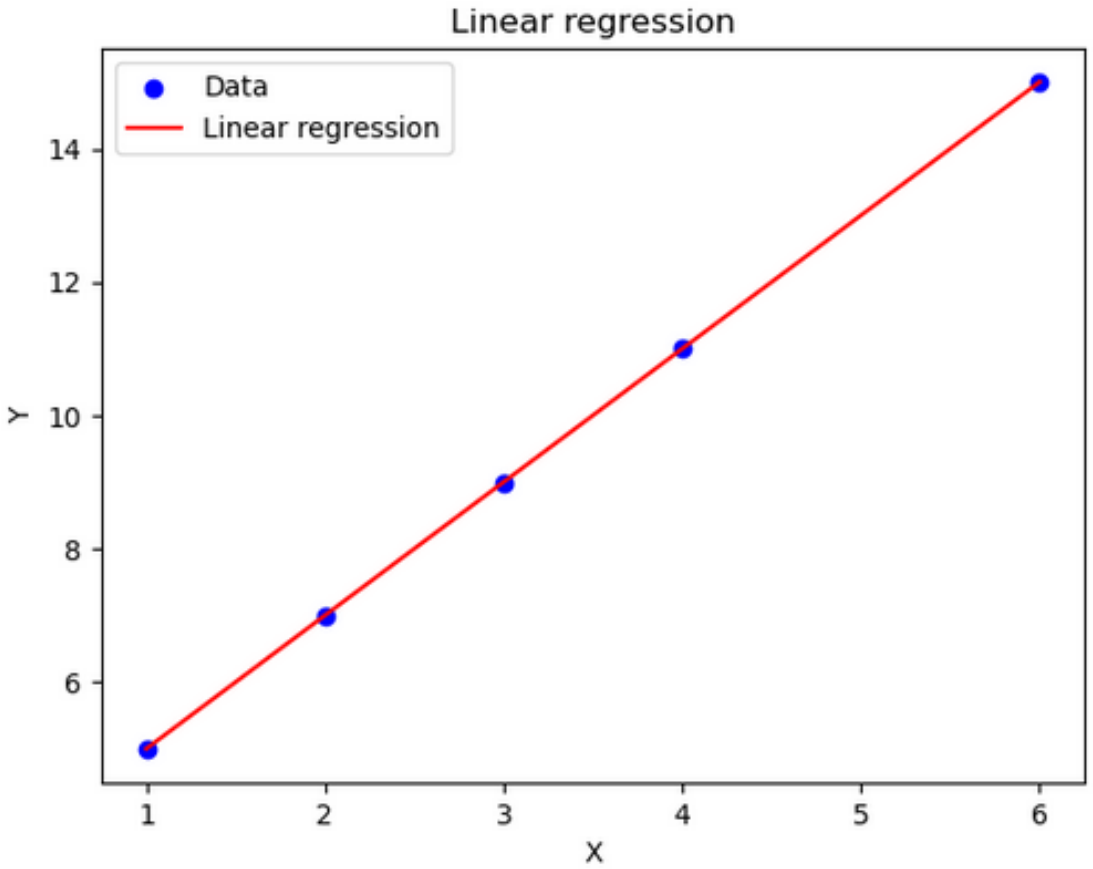

Linear regression

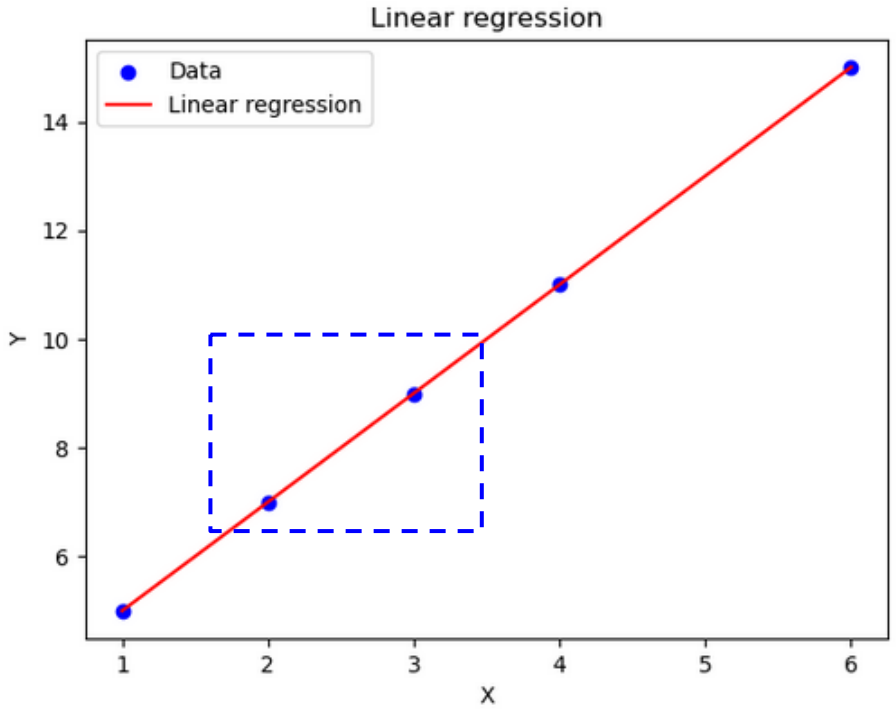

$$y = \beta_0 + \beta_1 x$$

คำนวณหาค่าความชันของสมการเส้นตรงได้ดังนี้

$$\beta_1 = \frac{y_2 - y_1}{x_2 - x_1} = \frac{9-7}{3-2} = 2$$

Linear regression

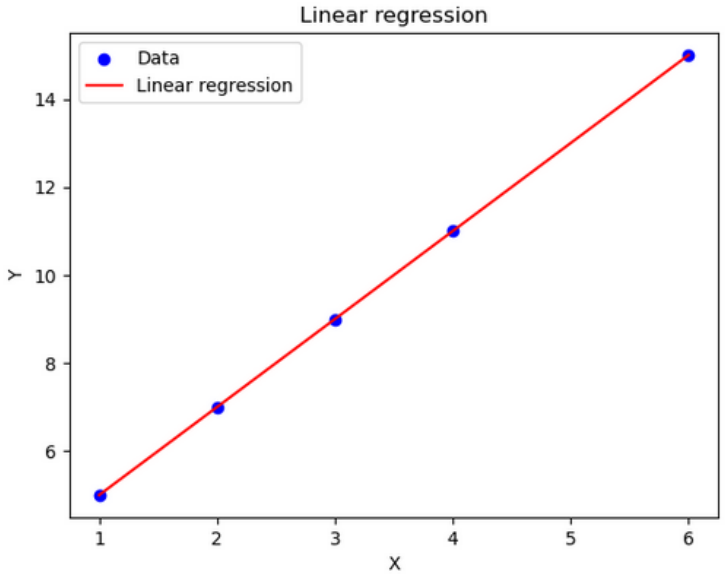

$$y = \beta_0 + \beta_1 x$$

จากนั้น นำค่า x และ y จากคู่อันดับไปคำนวณค่าจุดตันแกน y (β_1)

อย่างเช่น พิจารณาที่คู่อันดับ (2,7) จะได้

$$7 = \beta_0 + 2 \cdot 2$$

$$\beta_0 = 3$$

$$y = 3 + 2x$$

Linear regression

$$y = 2x + 3$$

เมื่ออยากรู้ค่า y ที่ค่า x อื่น ๆ สามารถคำนวณได้ดังตัวอย่างนี้ ในกรณีที่อยากรู้ค่า y ที่ค่า x เท่ากับ 7 นำค่า x เท่ากับ 7 แทนในสมการเส้นตรงจะได้ค่า y ดังนี้

$$y = 2 \cdot 7 + 3 = 17$$

Linear Regression และความสัมพันธ์ของข้อมูล

- Linear Regression จัดอยู่ในกลุ่ม Supervised Learning โดยข้อมูลตัวอย่างที่นำมา Train Model ชนิดนี้ จะต้องมีคอลัมน์ที่เป็นผลลัพธ์
- การพิจารณาว่าควรเลือกใช้โมเดล Linear Regression ในการทำนายผลหรือไม่
- ต้องดูจากข้อมูลตัวอย่างที่มีอยู่ ซึ่งหากข้อมูลนั้นให้ผลลัพธ์ออกมาเป็นตัวเลข แต่อาจเปลี่ยนแปลงในทิศทางเดียวกัน (เมื่อตัวหนึ่งเพิ่มอีกตัวหนึ่งก็เพิ่มตามกัน) หรือเปลี่ยนแปลงในทิศทางตรงกันข้ามก็ได้ (เมื่อตัวหนึ่งเพิ่ม อีกตัวหนึ่งลดลง) ก็คาดการณ์ในเบื้องต้นได้ว่า น่าจะใช้ Linear Regression ได้

Linear Regression และความสัมพันธ์ของข้อมูล

- กรณีที่ข้อมูลมีการเปลี่ยนแปลงไปในทางเดียวกัน (เมื่อตัวหนึ่งเพิ่มอีกตัวหนึ่งก็เพิ่มด้วย) หรือเราเรียกว่ามีความสัมพันธ์ต่อกันในเชิงบวก (Positive Correlation)

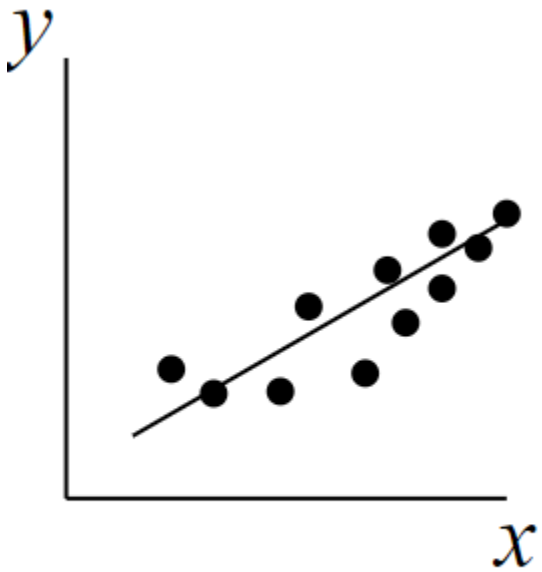

Positive

Linear Regression และความสัมพันธ์ของข้อมูล

- กรณีที่ข้อมูลมีการเปลี่ยนแปลงไปในทางตรงกันข้าม (เมื่อตัวหนึ่งเพิ่มอีกตัวหนึ่งลด) หรือเราเรียกว่ามีความสัมพันธ์ต่อกันในเชิงลบ (Negative Correlation)

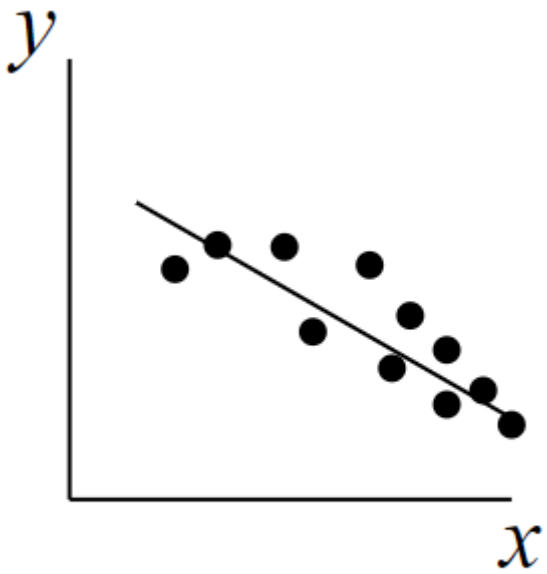

Negative

Linear Regression และความสัมพันธ์ของข้อมูล

- กรณีที่ข้อมูลไม่มีการเปลี่ยนแปลงตามกันอย่างชัดเจน (เมื่อตัวหนึ่งเพิ่มหรือลด อีกตัวหนึ่งอาจเปลี่ยนแปลงน้อยมาก หรือมีแนวโน้มที่ไม่แน่นอน) ซึ่งอาจเรียกว่า ไม่มีความสัมพันธ์ต่อกัน ไม่ควรทำนายด้วย Linear Regression

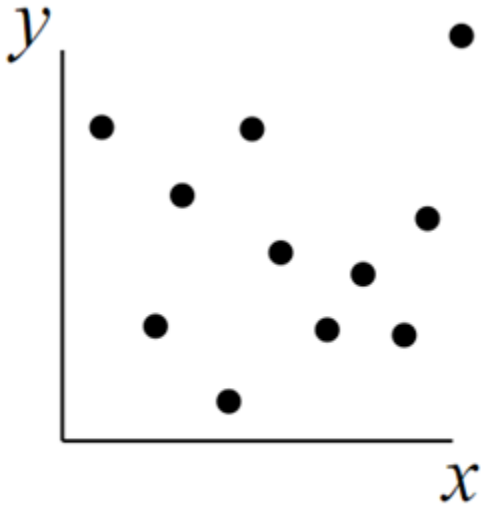

No correlation

Linear Regression และความสัมพันธ์ของข้อมูล


```
import matplotlib.pyplot as plt
import numpy as np
data = [[4, 10.5],[6,8],[7, 7],[8, 5],[10, 3.5]]
arr = np.array(data)
x = arr[:, 0]
y = arr[:, 1]
plt.figure(figsize=(4, 3))
plt.scatter(x, y, s = 50)
plt.show( )

import pandas as pd #pandas เป็นชื่อของ library ที่ถูกสร้างขึ้นมาเพื่อการจัดการและวิเคราะห์ข้อมูลตาราง
data = [[4, 10.5],[6,8],[7, 7],[8, 5],[10, 3.5]]
df = pd.DataFrame(data, columns=['x' , 'y'])
display(df.corr().round(3))
```

Linear Regression และความสัมพันธ์ของข้อมูล

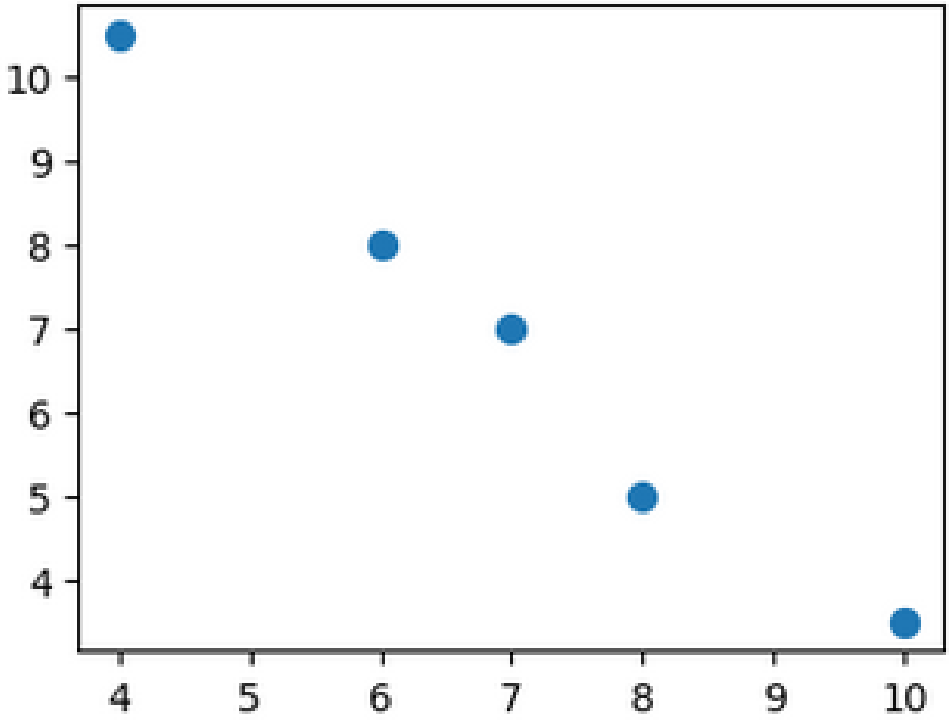

	x	y
x	1.000	-0.991
y	-0.991	1.000

Linear Regression และความสัมพันธ์ของข้อมูล


```python
import numpy as np #numpy เป็นชื่อของ library ที่ใช้ในการคำนวนทางคณิตศาสตร์
import matplotlib.pyplot as plt #matplotlib เป็นชื่อของ library ที่นิยมใช้มากที่สุดในการพลอตกราฟสองมิติจาก array

x = np.array([2, 4, 6, 8, 10, 12])
y = np.array([7, 10, 11, 15, 22, 25])

coefficients = np.polyfit(x, y, 1)
m = coefficients[0]  # ความชัน (slope)
b = coefficients[1]  # จุดตัดแกน y (intercept)
regression_line = m * x + b

plt.scatter(x, y, color='blue', label='Data')
plt.plot(x, regression_line, color='red', label='Linear regression')
plt.xlabel('X')
plt.ylabel('Y')
plt.title('Linear regression')
plt.legend()
plt.show()
```

Linear Regression และความสัมพันธ์ของข้อมูล

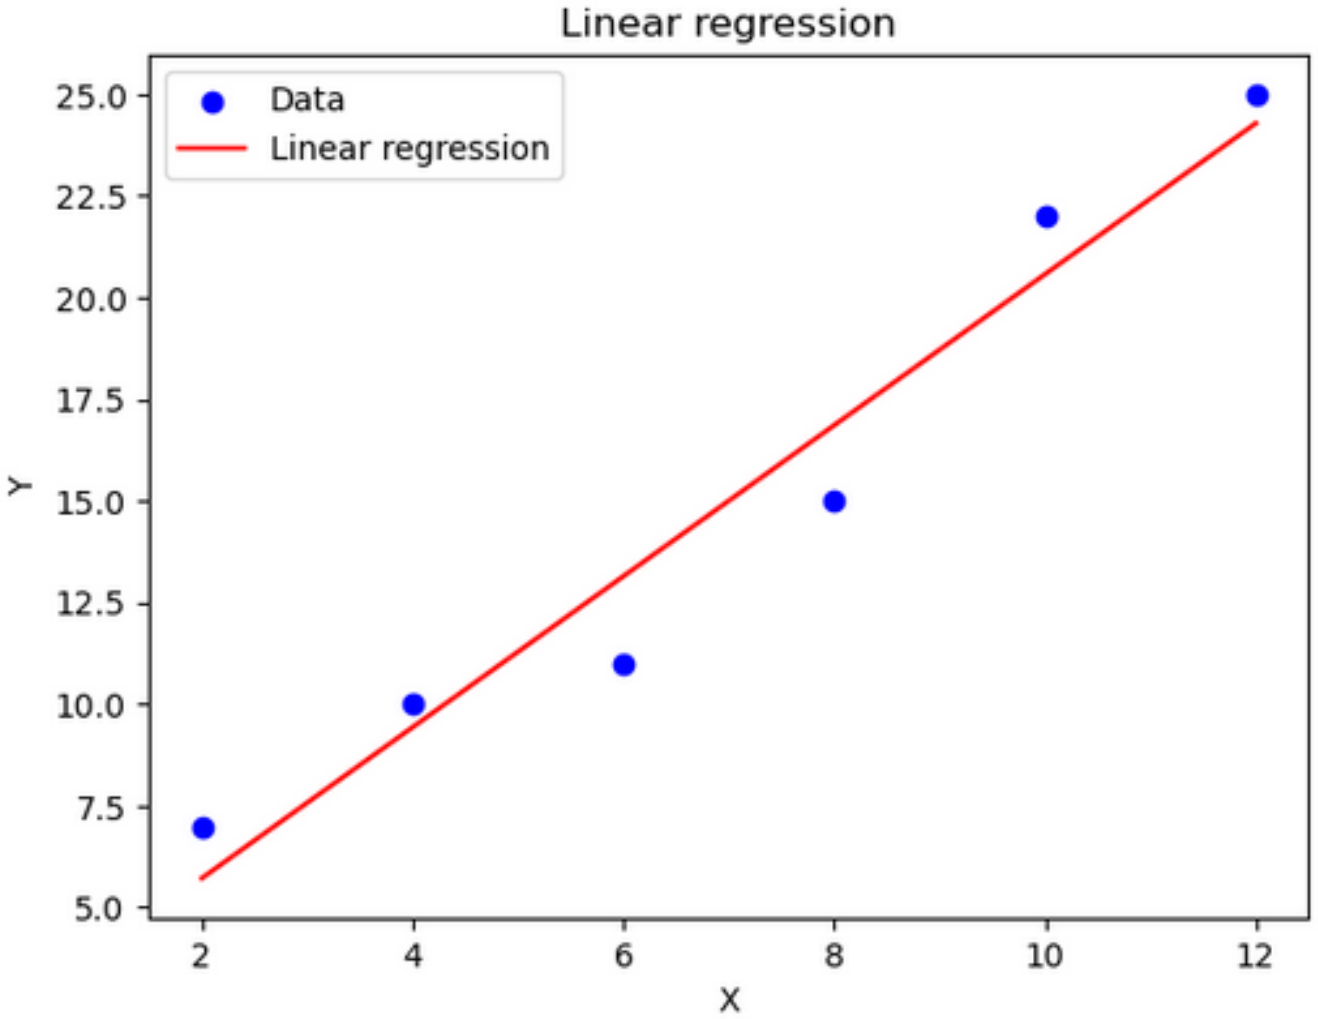

Simple Linear Regression

- Simple Linear Regression ใช้ในการทำนายผลสำหรับกรณีข้อมูลตัวอย่างประกอบด้วยคอลัมน์ที่เป็น Feature หรือตัวแปรอิสระ (x: Independence Variable) เพียงอันเดียว และคอลัมน์ที่เป็น Target หรือผลลัพธ์หรือตัวแปรตาม (y: Dependence Variable) มีค่าเป็นตัวเลข
- ทั้งตัวแปรอิสระและตัวแปรตาม มีความสัมพันธ์กับแบบ Positive หรือ Negative อย่างใดอย่างหนึ่ง

Simple Linear Regression

x	2	4	6	8	10	12
y	7	10	11	15	22	25

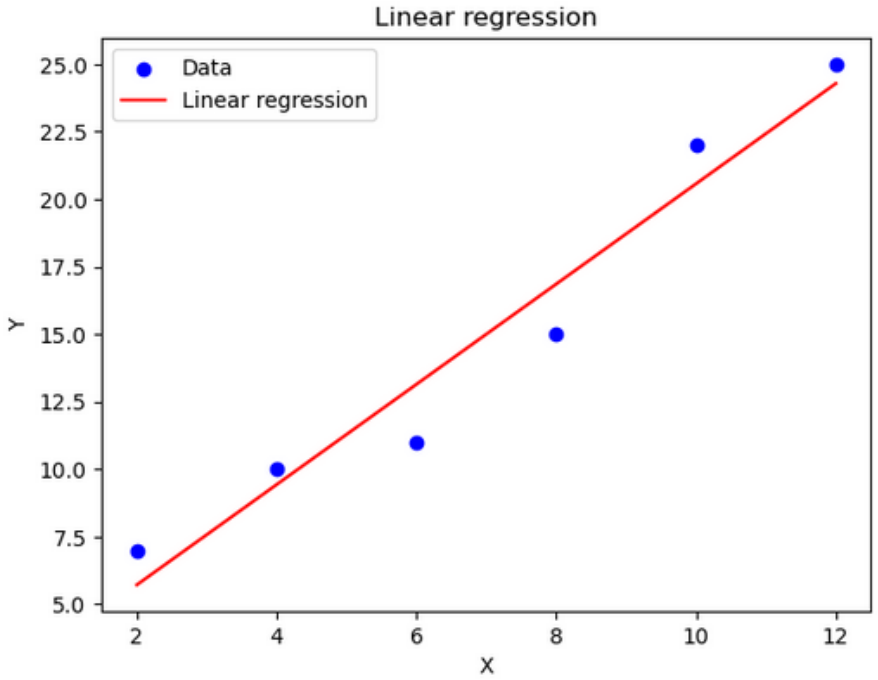

- จะเห็นว่าจุดต่าง ๆ ไม่ได้อยู่บนเส้นตรง Regression Line ซึ่งเส้นตรงดังกล่าวเป็นเพียงเส้นที่ใช้ในการประมาณค่า

Simple Linear Regression

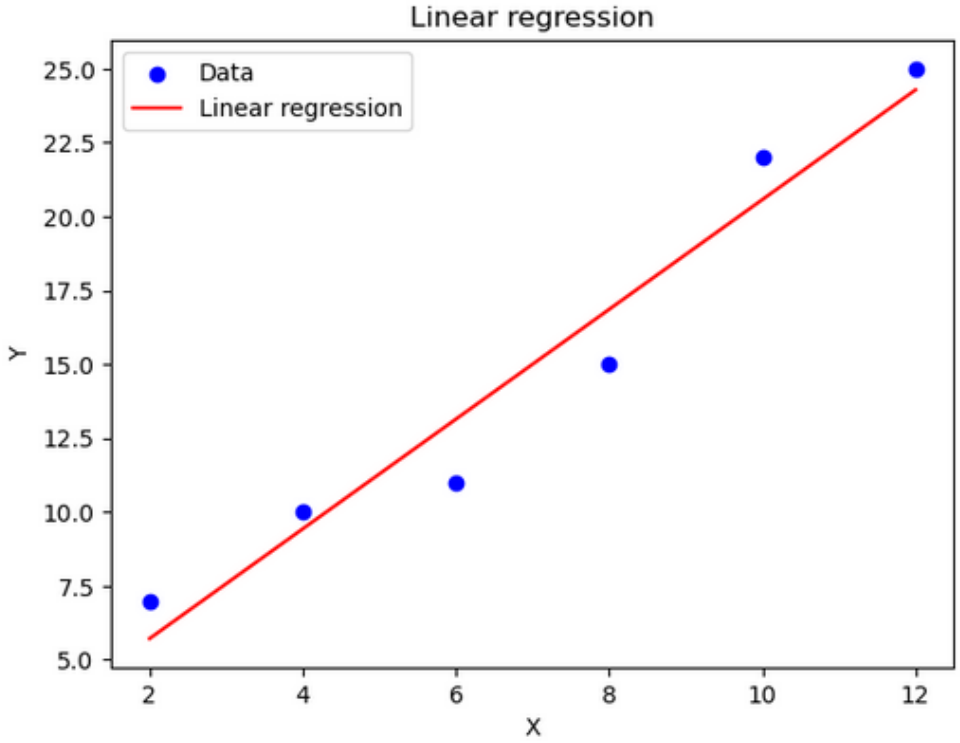

- เราไม่สามารถนำข้อมูลตัวอย่างที่มีอยู่มาใช้ในการคำนวณหา β_0 และ β_1 ด้วยวิธีการเดียวกับสมการเส้นตรง $y = mx + c$ ได้ แต่ต้องใช้สูตรการคำนาณที่แตกต่างออกไป

Linear Regression และความสัมพันธ์ของข้อมูล

$$y = \beta_0 + \beta_1 x$$

$$\beta_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Linear Regression และความสัมพันธ์ของข้อมูล

- x_i = คือรายการข้อมูลแต่ละคำในคอลัมน์ที่เป็น Feature หรือตัวแปรอิสระ
- $\bar{x}$ = คือค่าเฉลี่ยของข้อมูลในคอลัมน์ที่เป็นเป็น Feature
- y_i = คือรายการข้อมูลแต่ละคำในคอลัมน์ที่เป็น Target หรือตัวแปรตาม หรือผลลัพธ์นั่นเอง
- $\bar{y}$ = คือค่าเฉลี่ยของข้อมูลในคอลัมน์ที่เป็น Target

$$\beta_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Linear Regression และความสัมพันธ์ของข้อมูล

x	2	4	6	8	10	12
y	7	10	11	15	22	25

	A	B	C	D	E	
ลำดับ	x_i	y_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$y_i - \bar{y}$	C * E
1	2	7	2 – 7 = -5	25	7 – 15 = -8	40
2	4	10	-3	9	-5	15
3	6	11	-1	1	-4	4
4	8	15	1	1	0	0
5	10	22	3	9	7	21
6	12	25	5	25	10	50
ผลรวม	42	90		70		130
ค่าเฉลี่ย	$\bar{x} = 7$	$\bar{y} = 15$				

Linear Regression และความสัมพันธ์ของข้อมูล

$$\beta_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\beta_1 = 130/70 = 1.85$$

$$\beta_0 = 15 - (1.85 * 7) = 2.05$$

- สมการที่ใช้สำหรับการทำนายผลของข้อมูลชุดนี้คือ y = 2.05 + 1.85x
- หากเราต้องการทำนายผล เมื่อกำหนด x เป็นค่าอื่น ๆ ก็นำมาแทนลงในสมการ y = 2.05 + 1.85x

Linear Regression และความสัมพันธ์ของข้อมูล

- หากเราต้องการทำนายผล เมื่อกำหนด x เป็นค่าอื่น ๆ ก็นำมาแทนลงในสมการ

$y = 2.05 + 1.85x$

$y\_7 = 2.05 + (1.85 * 7) = 15$

$y\_9 = 2.05 + (1.85 * 9) = 18.7$

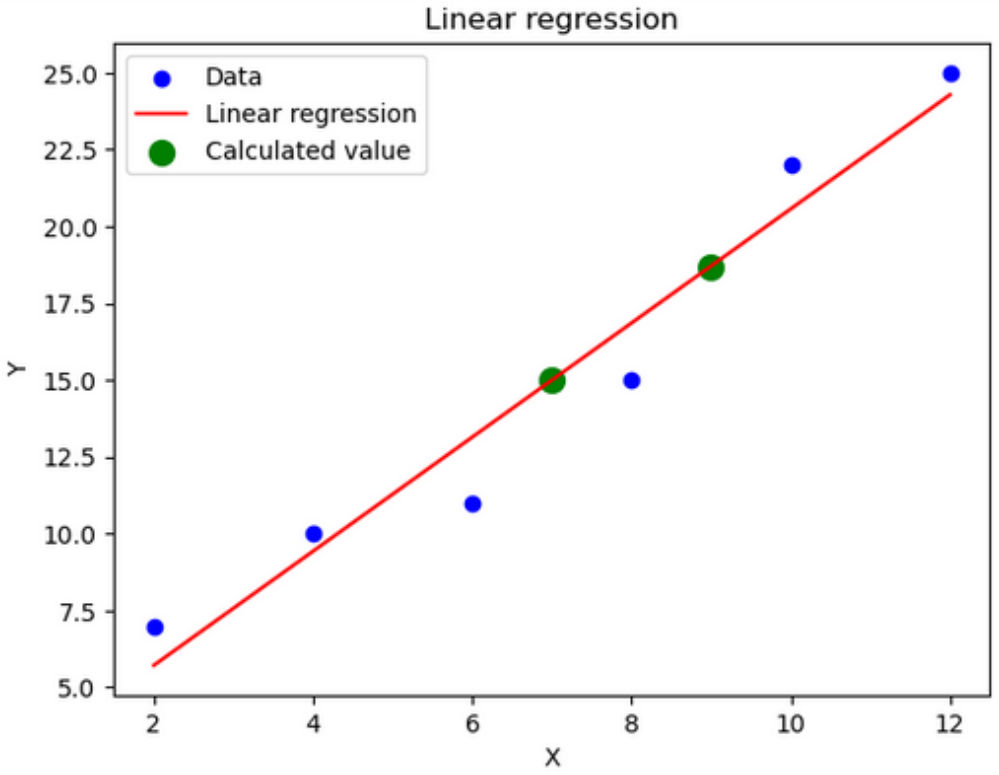

การทำนายผลด้วย Scikit-Learn

- การใช้งาน Scikit-Learn เพื่อทำนายผลของโมเดลแบบ Simple Linear Regression มีแนวทางดังนี้
- คลาสสำหรับโมเดลนี้คือ LinearRegression โดยต้องอิมพอร์ตจากโมดูล sklearn.linear_model แล้วสร้างอินสแตนซ์ของมัน

```
from sklearn.linear_model import LinearRegression
...
model = LingarRegression () #สร้างอินสแตนซ์ของคลาส LinearRegression
```

Linear Regression และความสัมพันธ์ของข้อมูล

- ในเบื้องต้น เราอาจสมมติข้อมูลขึ้นมาเองในแบบลิสต์หรืออาร์เรย์ 2 มิติ โดยข้อกำหนดที่สำคัญคือ
  - ค่าในแต่ละแถวของคอลัมน์ที่เป็น Feature (x) ต้องอยู่ในรูปแบบอาร์เรย์ 2 มิติ แม้แต่ละแถวจะมีค่าเดียวก็ตาม
  - ค่าในแต่ละแถวของคอลัมน์ที่เป็น Target (y) อาจอยู่ในรูปแบบอาร์เรย์มิติเดียว หรือ 2 มิติก็ได้
  - ข้อมูลต้องมีความสัมพันธ์แบบ Positive หรือ Negative Correlation อย่างใดอย่างหนึ่ง

Linear Regression และความสัมพันธ์ของข้อมูล

- ตัวอย่าง การทำนายผลด้วย Scikit-Learn ของข้อมูลตัวอย่างชุดเดิมที่ใช้ประกอบการอธิบายไปก่อนนี้

```
from sklearn.linear_model import LinearRegression
import numpy as np
x = [2, 4, 6, 8, 10, 12]
x = np.array(x).reshape (-1, 1)
y = [7, 10, 11, 15, 22, 25]
model = LinearRegression()
model.fit(x, y)

y_7 = model.predict([[7]])
print('x = 7, y =', y_7[0])
y_9 = model.predict([[9]])
print('x = 9, y =', y_9[0])
print('intercept =', model.intercept_)
print('coefficient =', model.coef_[0])
```

x	2	4	6	8	10	12
y	7	10	11	15	22	25

```
x = 7, y = 15.0
x = 9, y = 18.714285714285715
intercept = 2.0
coefficient = 1.8571428571428572
```

y = 2.05 + 1.85x

y_7 = 2.05 + (1.85 * 7) = 15

y_9 = 2.05 + (1.85 * 9) = 18.7

Linear Regression และความสัมพันธ์ของข้อมูล

- ตัวอย่าง สมมติว่าเรามีข้อมูลเกี่ยวกับราคาที่ดิน ในหน่วยล้านบาท ซึ่งสัมพันธ์กับจำนวนปีที่ผ่านไปดังตาราง หากเราต้องการทำนายผลราคาที่ดินในปีที่ 17 และ 20 สามารถทำได้ดังนี้

years	3	5	7	10	15
land price (million baht)	5	5.5	6.2	6.8	7.7

Linear Regression และความสัมพันธ์ของข้อมูล

- จากการพิจารณาข้อมูลในตารางด้วยสายตา เราพอจะคาดคะเนได้ว่าข้อมูลทั้ง 2 มีความสัมพันธ์กันแบบ Positive แต่เพื่อให้แน่ใจ เราลอง plot กราฟดู ได้รูปกราฟดังนี้

years	3	5	7	10	15
land price (million baht)	5	5.5	6.2	6.8	7.7

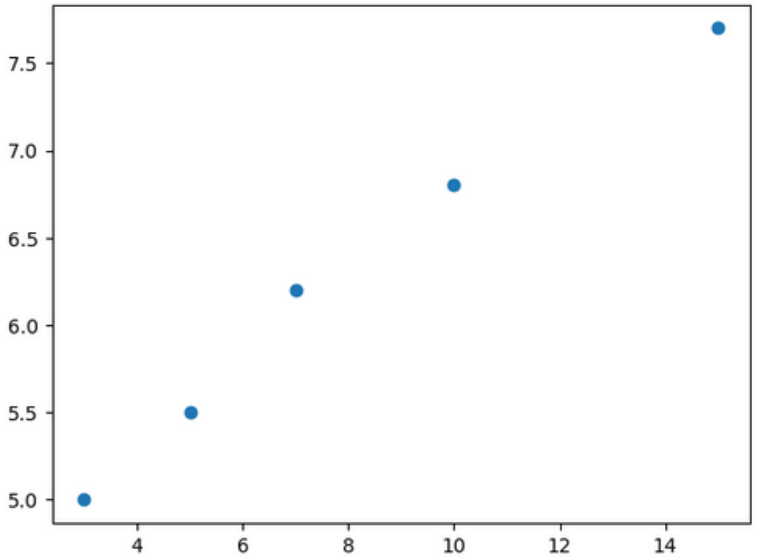

Linear Regression และความสัมพันธ์ของข้อมูล


```
import matplotlib.pyplot as plt
x = [3, 5, 7, 10, 15]
y = [5, 5.5, 6.2, 6.8, 7.7]
plt.scatter(x, y)
plt.show( )

x = np.array(x).reshape(-1 , 1)
model = LinearRegression()
model.fit (x , y)
x_predict = [[17], [20]] #ทำนายราคาที่ดินปีที่ 17 และ 20
y_predict = model.predict(x_predict)

ic = '{:.2f}'.format(model.intercept_)
ce = '{:.2f}'.format(model.coef_[0])

print(f'y = {ic} + {ce}x')

price_17 = '{:.2f}'.format(y_predict[0])
price_20 = '{:.2f}'.format(y_predict[1])

print (f'year 17, land price is {price_17} million baht')
print (f'year 20, land price is {price_20} million baht')
```

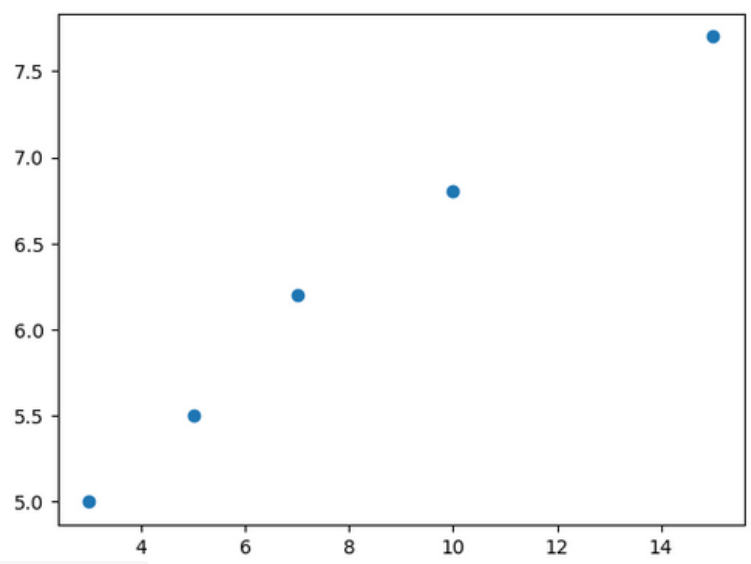


```
y = 4.44 + 0.23x
year 17, land price is 8.27 million baht
year 20, land price is 8.94 million baht
```

Linear Regression และความสัมพันธ์ของข้อมูล

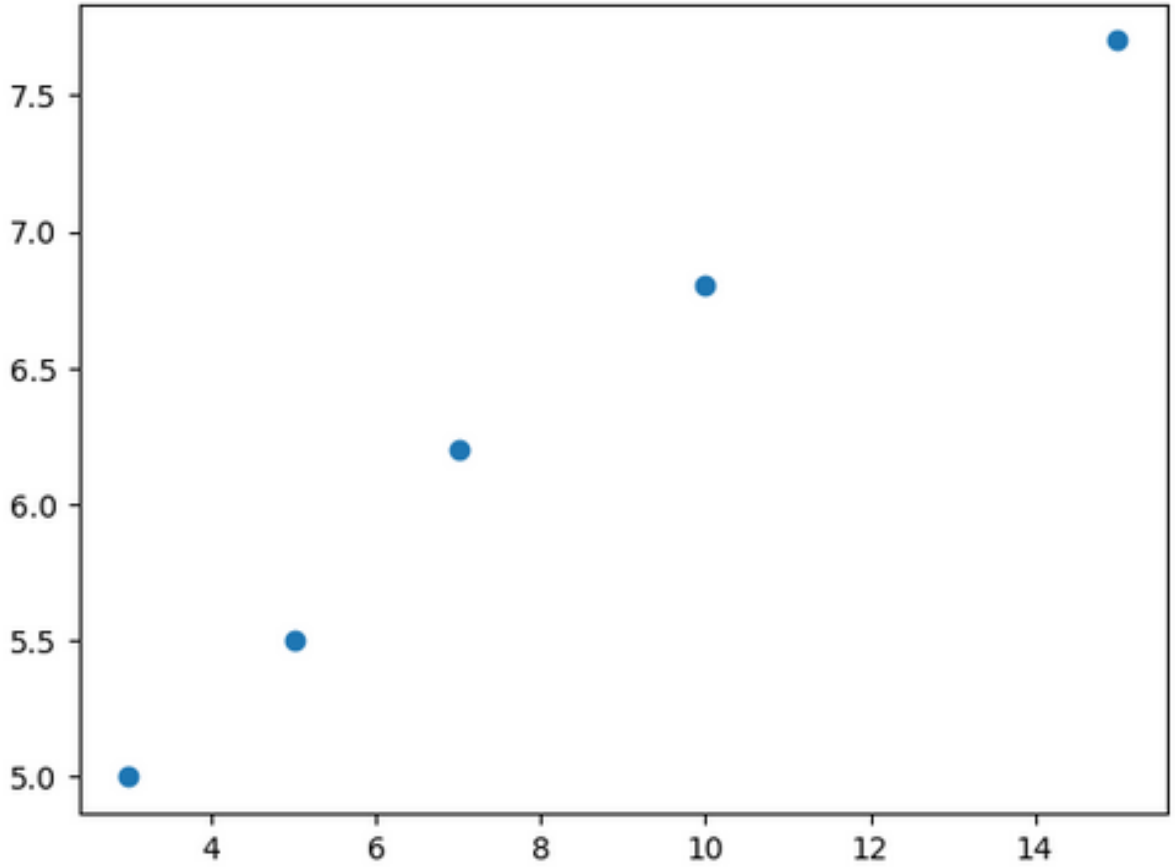


```
y = 4.44 + 0.23x
year 17, land price is 8.27 million baht
year 20, land price is 8.94 million baht
```

Question

- หากเรามีข้อมูลเกี่ยวกับเงินเดือน ในหน่วยบาท ซึ่งสัมพันธ์กับจำนวนปีที่ทำงาน ให้ทำนายเงินเดือนเมื่อทำงานครบ 10, 12 และ 15 ปี

years	1	3	7	8
Salary (baht)	25000	27000	34000	35000

Logistic Regression

Logistic Regression

- Logistic Regression จัดอยู่ในกลุ่ม Supervised Learning ที่ทำนายผลแบบ Classification (แม้ชื่อโมเดลจะมีคำว่า Regression ก็ตาม)
- นอกจากนี้ ก็ยังจะกล่าวถึงการประเมินโมเดลจาก Confusion Matrix ซึ่งสามารถนำไปใช้กับโมเดลชนิดอื่น ๆ ที่ทำนายผลแบบ Classification ได้ทั้งหมด

Logistic Regression

- $\log_b(x) = y$ หมายถึง $b^y = x$
- $\log_2(8) = 3$ เพราะ $2^3 = 8$
- $\log_2(32) = a$ มีความหมายว่า $2^a = 32$ นั่นคือ $a = 5$
  เพราะ $2^5 = 32$
- ในกรณีที่เป็น **logarithm** ฐาน 10 เราอาจไม่ระบุเลขฐานก็ได้
- $\log_{10}(100)$ อาจเขียนเป็น $\log(100)$

Logistic Regression

- ส่วน Natural Logarithm คือกรณีที่เลขฐานของมันมีค่าเป็น 2.718281828459 หรือเรียกว่า Euler's number ซึ่งโดยทั่วไป เรามักใช้เพียงทศนิยม 2 - 3 ตำแหน่ง
- $\log_{2.718}(10) = a$ หมายถึง $2.718^a = 10$ นั่นคือ $a = 2.302$ เพราะ $2.718^{2.302} \approx 10$
- โดยส่วนใหญ่เราจะแทนเลขฐานด้วยตัว e เช่น $\log_e(100) = 4.605$ หรือเขียนแทน $\log_e$ ด้วยสัญลักษณ์ ln ในลักษณะดังนี้

$$\log_e(x) = \ln(x)$$

$$\ln(100) = 4.605 \quad \text{เพราะ } e^{4.605} = 2.718^{4.605} \approx 100$$

Logistic Regression

- สูตรที่น่าสนใจอื่น ๆ ของ Logarithm
- $\ln(a * b) = \ln(a) + \ln(b)$
- $\ln(a/b) = \ln(a) - \ln(b)$
- $\ln(a^b) = b * \ln(a)$

Logistic Regression

- Odds Ratio และ Logit Function เป็นพื้นฐานที่จะนำไปสู่ Logistic Function
- โอกาสหรือความน่าจะเป็น (Probability) ที่จะได้ผลลัพธ์ที่เราต้องการ คือ (ให้ P แทนความน่าจะเป็นที่สิ่งนั้นจะเกิดขึ้น)

$$P = \frac{\text{จำนวนเหตุการณ์ที่จะเกิดสิ่งนั้น}}{\text{จำนวนเหตุการณ์ที่เป็นไปได้ทั้งหมด}}$$

Logistic Regression

- ความน่าจะเป็นต้องมีค่าอยู่ระหว่าง 0 - 1 ($0 \leq P \leq 1$)
- ถ้าเราโยนเหรียญ 1 ครั้ง ความน่าจะเป็นที่จะได้ หัว หรือ ก้อย เท่ากับ 1/2
- การทอยลูกเต๋าแต่ละครั้ง ความน่าจะเป็นที่จะได้แต้มที่ต้องการ เท่ากับ 1/6
- ถ้าความน่าจะเป็นที่เกิดเหตุการณ์นั้น = P แสดงว่า ความน่าจะเป็นที่จะ **ไม่** เกิดเหตุการณ์นั้น = $1 - P$
- โอกาสที่สลากกินแบ่งแต่ละใบจะถูกรางวัลเลขท้าย 2 ตัว (00 - 99) เท่ากับ 1/100 = 0.01
- โอกาสที่จะ **ไม่** ถูกรางวัลเลขท้าย 2 ตัว จึงเท่ากับ 1 - 0.01 = 0.99

Logistic Regression

- Odds Ratio เป็นอัตราส่วนระหว่าง ความน่าจะเป็นที่จะเกิดสิ่งใดสิ่งหนึ่ง กับ ความน่าจะเป็นที่จะไม่เกิดสิ่งนั้น

$$\text{odds} = \frac{\text{ความน่าจะเป็นที่จะเกิดสิ่งนั้น}}{\text{ความน่าจะเป็นที่จะไม่เกิดสิ่งนั้น}} = \frac{P}{1-P}$$

Logistic Regression

- Logit Function ก็คือ Natural Logarithm ของ Odds Ratio

$$\text{logit} = \ln\left(\frac{P}{1-P}\right)$$

- เนื่องจาก P มีค่าระหว่าง 0 - 1 ดังนั้น ถ้าเรานำไปแทนค่าเพื่อดูขอบเขตของ logit จะได้ดังนี้
- $\text{logit}(0) = \ln(0/(1-0)) = \ln(0) = -\infty$
- $\text{logit}(1) = \ln(1/(1-1)) = \ln(\infty) = \infty$

Logistic Regression

- logit จะมีค่าระหว่าง $(-\infty, \infty)$ ซึ่งหากเรามาวาดกราฟด้วย Matplotlib ก็จะเป็นดังภาพถัดไป หรือเรียกว่า Logit Curve

```
import numpy as np
import matplotlib.pyplot as plt
x = np.linspace(0, 0.999, num=100)
y = np.log(x/(1-x))
plt.plot(x, y)
plt.grid()
plt.show()
```

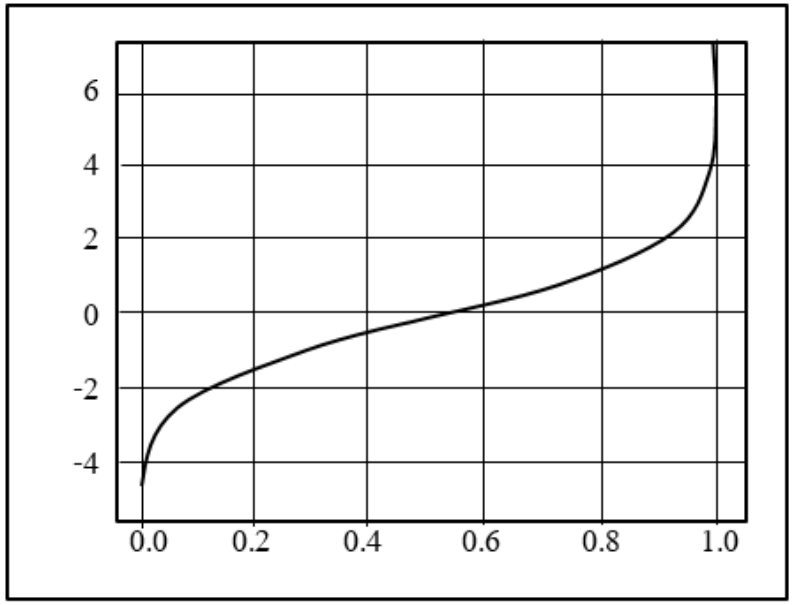

Logistic Regression

- Sigmoid Function คือฟังก์ชันที่ใช้ในการแปลงช่วงตัวเลขจาก $(-\infty,\infty)$ ไปเป็นช่วงตัวเลขระหว่าง $(0, 1)$ ซึ่งจากกราฟ Logit Curve ที่มีค่าระหว่าง $(-\infty,\infty)$ ดังที่กล่าวมา หากนำไปแปลงเป็นช่วงระหว่าง $(0, 1)$ ก็จะได้ Sigmoid Curve ในลักษณะดังภาพถัดไป

Logistic Regression

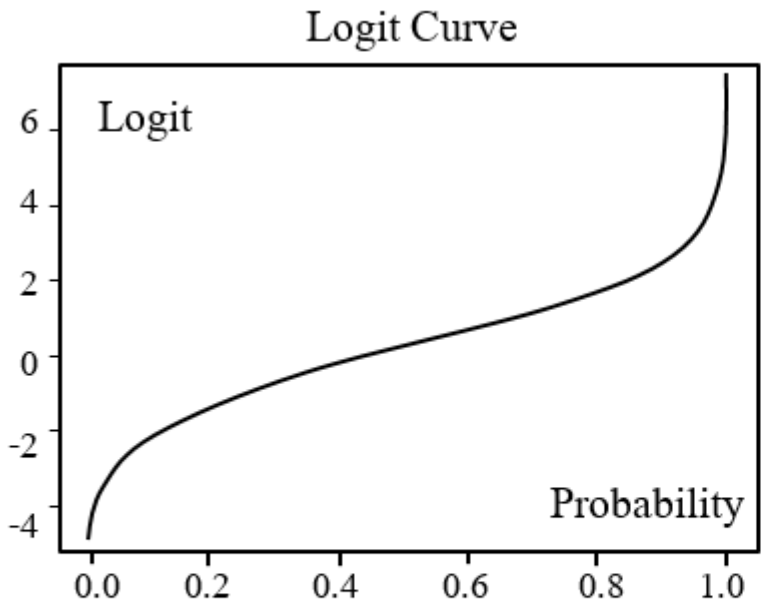

Inverse

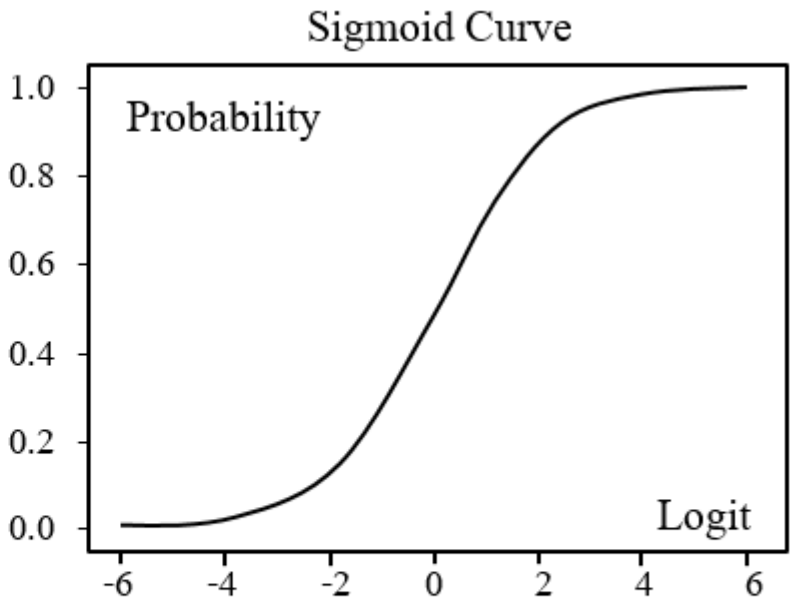

$$\text{logit} = \ln\left(\frac{P}{1 - P}\right)$$

$$P = \frac{1}{1 + e^{-\text{logit}}}$$

Logistic Regression

$$L = \ln\left[\frac{P}{1-P}\right]$$

$$e^{L} = \frac{P}{1-P}$$

$$\frac{1-P}{P} = \frac{1}{e^{L}}$$

$$e^{L} - Pe^{L} = P$$

$$e^{L} = P + Pe^{L} = P(1 + e^{L})$$

$$P = \frac{e^{L}}{1+e^{L}} = \frac{1}{\frac{1}{e^{L}} + 1} = \frac{1}{e^{-L} + 1}$$

$$\text{sigmoid} = \frac{1}{1+e^{-L}}$$

Logistic Regression

- Sigmoid Function ก็เหมือนกับการหาความน่าจะเป็นที่จะเกิดเหตุการณ์อย่างใดอย่างหนึ่ง ซึ่งมีค่าระหว่าง 0 – 1

```
import numpy as np
import matplotlib.pyplot as plt
x = np.linspace (-6, 6, 121)
y = 1/(1 + np.exp(-x))
plt.plot(x, y)
plt.grid()
plt.show()
```

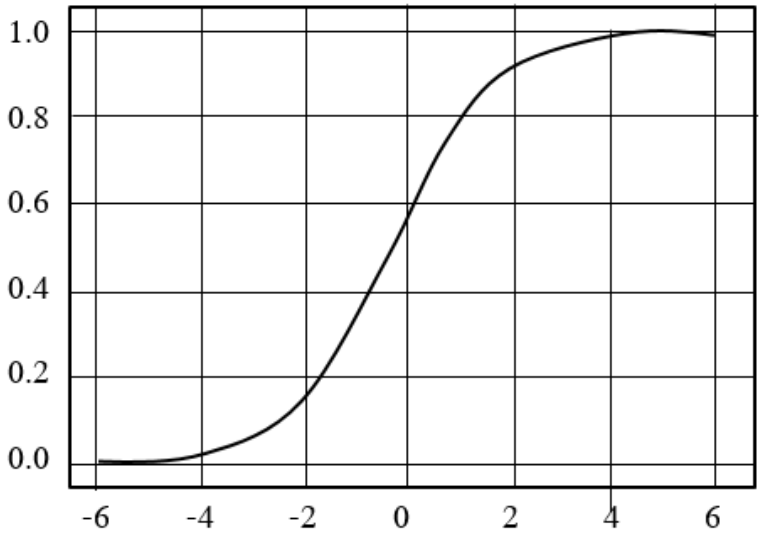

Logistic Regression

- Sigmoid Function จะถูกนำไปใช้สำหรับการทำนายผลแบบ Logistic Regression ด้วยเหตุนี้ เราอาจ เรียก Sigmoid Function อีกอย่างว่าเป็น Logistic Function
- Logistic Regression เป็นโมเดลที่จัดอยู่ในประเภท Supervised Learning สำหรับการทำนายผลแบบ Classification แม้ชื่อโมเดลจะลงท้ายด้วยคำว่า Regression ก็ตาม

Logistic Regression

- ข้อมูลตัวอย่างแต่ละรายการจะมี คอลัมน์ที่เป็น Target (หรือผลลัพธ์ หรือตัวแปรตาม : y) ที่สามารถจำแนกประเภทหรือแบ่งได้เป็น 2 กลุ่ม เช่น Yes/No, True/False, Success/Fail, High/Low, Male/Female, R/X, 1/0
- ส่วนคอลัมน์ที่เป็น Feature หรือตัวแปรอิสระ (x) อาจมีตั้งแต่ 1 คอลัมน์ขึ้นไป เช่นเดียวกับ Linear Regression

Logistic Regression

x	y
4	No
7.2	Yes
5.1	Yes
3.2	No
8	Yes

x1	x2	y
7	5	0
3	4	1
2	8	0
6	7	1
8	7	1

Logistic Regression

- กรณีที่มีตัวแปรอิสระเพียงตัวเดียว

$$y = \beta_0 + \beta_1 x$$

$$y = 3.2 + 1.5x$$

- กรณีที่มีตัวแปรอิสระหลายตัว

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k$$

$$y = \beta_0 + \Sigma \beta_i x_i$$

$$y = 5.2 + 3.5x_1 + 4x_2 + 7x_3$$

Logistic Regression

- ถ้าความน่าจะเป็นขึ้นกับตัวแปรอิสระ x_1, x_2, x_3, ... แสดงว่า Logit Function ก็มีรูปแบบเหมือนกับ สมการของ Linear Regression

$$\text{logit} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k$$

$$= \beta_0 + \Sigma \beta_i x_i$$

$$P = \frac{1}{1 + e^{-\text{logit}}}$$

$$P(x) = \frac{1}{1 + e^{-(\beta_0 + \Sigma \beta_i x_i)}}$$

Logistic Regression

- Logistic Regression ก็คือการหาความน่าจะเป็นด้วย Sigmoid Function ทั้งนี้หากเราทราบค่า **intercept** และ **coefficient** ก็สามารถนำตัวแปรอิสระ x_1, x_2, ... มาแทนค่าในฟังก์ชัน ก็จะได้ค่าความน่าจะเป็นออกมา
- อย่างไรก็ตาม ความน่าจะเป็นต้องมีค่าระหว่าง 0 - 1 ในขณะที่ผลลัพธ์ของ Logistic Regression จะต้องอยู่ในรูปแบบ Classification ที่จำแนกได้ 2 กลุ่ม เช่น Yes/No ซึ่งไม่สอดคล้องกัน จึงต้องนำค่าความน่าจะเป็นที่ได้ไปทำการเปรียบเทียบต่อ ดังนี้

Logistic Regression

- หากความน่าจะเป็นมีค่าระหว่าง 0 - 0.5 จะทำนายผลเป็นคลาสกลุ่มที่ 1
- หากความน่าจะเป็นมีค่าระหว่าง 0.5 - 1 จะทำนายผลเป็นคลาสกลุ่มที่ 2

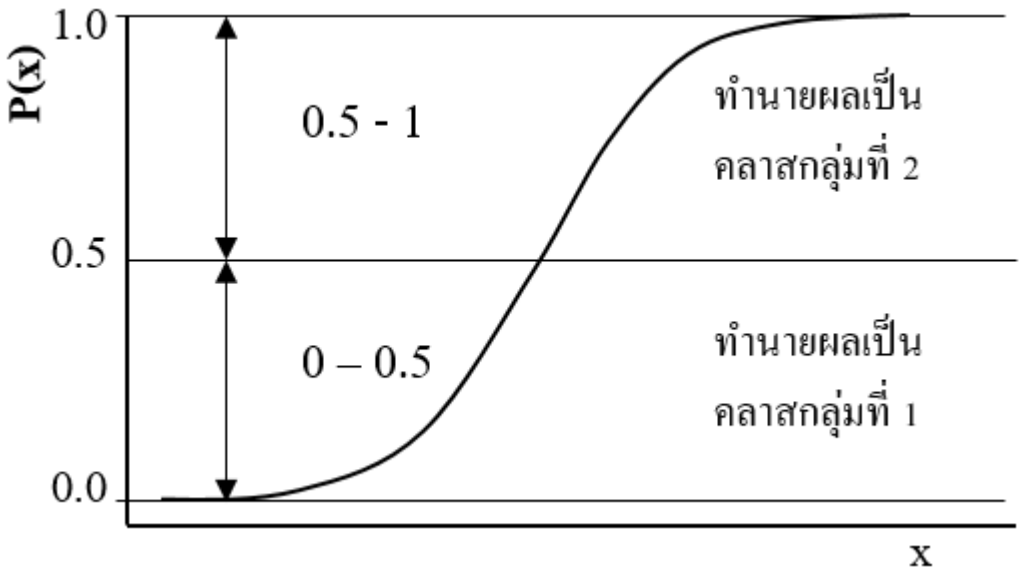

- จากสมการของ P(x) ต่อไปนี้เป็นขั้นตอนการคำนวณค่า β_0 และ β_i

$$P(x) = \frac{1}{1 + e^{-(\beta_0 + \Sigma\beta_i x_i)}}$$

$$y = \beta_0 + \Sigma\beta_i x_i$$

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

$$A = \sum x_1^2 - \frac{(\sum x_1)^2}{N} \qquad B = \sum x_2^2 - \frac{(\sum x_2)^2}{N}$$

$$C = \sum x_1 y - \frac{(\sum x_1)(\sum y)}{N} \qquad D = \sum x_2 y - \frac{(\sum x_2)(\sum y)}{N}$$

$$E = \sum x_1 x_2 - \frac{(\sum x_1)(\sum x_2)}{N}$$

x_1	x_2	y
7	5	0
3	4	1
2	8	0
6	7	1
8	7	1

$$\beta_1 = \frac{(B)(C)-(E)(D)}{(A)(B)-(E)^2}$$

$$\beta_2 = \frac{(A)(D)-(E)(C)}{(A)(B)-(E)^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}_1 - \beta_2 \bar{x}_2$$

Logistic Regression

- จากสมการของ P(x) การคำนวณค่า β_0 และ β_i ค่อนข้างใช้เวลาในการคำนวณ
- เราสามารถนำ Scikit-Learn มาช่วยในการคำนวณ

Logistic Regression

- ตัวอย่างที่ 1 จากการสำรวจนักเรียนกลุ่มหนึ่งพบว่า การสอบผ่าน Pass หรือสอบตก Fail ขึ้นกับชั่วโมงการเรียน (hours_study) ดังตาราง ถ้าเรานำมา Train Model แบบ Logistic Regression แล้วทำนายผล ในกรณีที่ศึกษา 3.2, 3.75 และ 7 ชั่วโมง จะแสดงขั้นตอนได้ดังนี้

hours_study	pass
0	Fail
1	Fail
2	Fail
3	Fail
4	Pass
5	Pass
6	Pass

Logistic Regression


```
import numpy as np
from sklearn.linear_model import LogisticRegression

x = [[0], [1], [2], [3], [4], [5], [6]] #[[x1]. ...]
y = ['Fail', 'Fail', 'Fail', 'Fail', 'Pass', 'Pass', 'Pass']
model = LogisticRegression()
model.fit(x, y)

x_predict = [3.2, 3.75, 7]
x_predict = np.array(x_predict).reshape(-1, 1)
y_predict = model.predict(x_predict)
print('Prediction:')

for (i, xp) in enumerate (x_predict):
    print(f'study: {xp[0]} hours =>', y_predict[i])
print()

print('Logistic Function:')
ic = '{:.2f}'.format(model. intercept_[0])
ce = '{:.2f}'.format(model.coef_[0,0])
print (f'P(x) = 1 / (1 + exp({ic} + ({ce})x))')
```

Logistic Regression


```
import numpy as np
from sklearn.linear_model import LogisticRegression

x = [[0], [1], [2], [3], [4], [5], [6]] #[[x1]. ...]
y = ['Fail', 'Fail', 'Fail', 'Fail', 'Pass', 'Pass', 'Pass']
model = LogisticRegression()
model.fit(x, y)

x_predict = [3.2, 3.75, 7]
x_predict = np.array(x_predict).reshape(-1, 1)
y_predict = model.predict(x_predict)
print('Prediction:')

for (i, xp) in enumerate (x_predict):
    print(f'study: {xp[0]} hours =>', y_predict[i])
print()

print('Logistic Function:')
ic = '{:.2f}'.format(model. intercept_[0])
ce = '{:.2f}'.format(model.coef_[0,0])
print (f'P(x) = 1 / (1 + exp({ic} + ({ce})x))')
```

```
Prediction:
study: 3.2 hours => Fail
study: 3.75 hours => Pass
study: 7.0 hours => Pass

Logistic Function:
P(x) = 1 / (1 + exp(-4.03 + (1.15)x))
```

Logistic Regression

- ตัวอย่างที่ 2 หากเรามีข้อมูลดังตารางในภาพ ถ้านำมา Train Model แบบ Logistic Regression ให้ทำนายผลเมื่อ $x_1=3, x_2=3$ และ $x_1=5, x_2=6$

x_1	x_2	y
7	6	yes
2	4	no
5	8	yes
4	7	no
8	10	yes

Logistic Regression


```
from sklearn.linear_model import LogisticRegression
model = LogisticRegression()
x = [[7, 6], [2, 4], [5, 8], [4, 7], [8, 10]] #[[x1, x2]. ...]
y = ['yes', 'no', 'yes', 'no', 'yes']
model.fit(x, y)

#ทำนายผลเมื่อ x1=3, x2=3 และ x1=5, x2=6
x_predict = [[3, 3], [5, 6]]
y_predict = model.predict(x_predict)

print('X = [3, 3], y =', y_predict[0])
print('X = [5, 6], y =', y_predict[1])
print()
print('probabiltiy')
prob = model.predict_proba(x_predict)
print(prob)
print('      1-P         P')
```

Logistic Regression


```
from sklearn.linear_model import LogisticRegression
model = LogisticRegression()
x = [[7, 6], [2, 4], [5, 8], [4, 7], [8, 10]] #[[x1, x2]. ...]
y = ['yes', 'no', 'yes', 'no', 'yes']
model.fit(x, y)

#ทำนายผลเมื่อ x1=3, x2=3 และ x1=5, x2=6
x_predict = [[3, 3], [5, 6]]
y_predict = model.predict(x_predict)

print('X = [3, 3], y =', y_predict[0])
print('X = [5, 6], y =', y_predict[1])
print()
print('probabiltiy')
prob = model.predict_proba(x_predict)
print(prob)
print('      1-P         P')
```

```
X = [3, 3], y = no
X = [5, 6], y = yes

probabiltiy
[[0.93074277 0.06925723]
 [0.46291989 0.53708011]]
      1-P         P
```

Question

- บริษัทแห่งหนึ่งได้ทดสอบการทำงานของเครื่องจักรพบว่า อายุของเครื่องจักร (หน่วยเป็น เดือน) และจำนวนชั่วโมงการทำงานต่อวัน มีผลต่อสมรรถนะของเครื่องจักร ดังตาราง ให้ทำนายผลในกรณีที่

1) อายุของเครื่องจักรเท่ากับ 40 เดือน และทำงาน 3 ชั่วโมงต่อวัน

2) อายุของเครื่องจักรเท่ากับ 70 เดือน และทำงาน 2 ชั่วโมงต่อวัน

และให้หา Logistic Function

machine_age (months)	operate_hours_per_day	performance
59	4	Not good
15	4	Good
78	8	Not good
22	6	Good
38	5	Good
71	7	Not good
35	4	Not good
44	5	Good

Confusion Matrix

- ถ้าเราต้องการประเมินการทำนายผลของโมเดล หากเป็นกรณีของ Linear Regression ที่เราได้ศึกษามา ก็สามารถนำผลลัพธ์จริง (y_true) และผลการทำนาย (y_predict) มาคำนวณค่าต่าง ๆ ที่เกี่ยวข้องได้เลย เพราะมีค่าเป็นตัวเลข
- กรณีของ Logistic Regression ซึ่งผลการทำนายเป็นแบบ Classification เราจึงไม่สามารถทำเช่นนั้นได้ แต่ต้องใช้วิธีการนับจำนวนรายการที่ทำนายถูก (y_true = y_predict) และจำนวนรายการที่ทำนายผิด (y_true != y_predict) แล้วมาเปรียบเทียบกัน

Confusion Matrix

	Predict: Negative (N)	Predict: Positive (P)
Actual: Negative	TN	FP
Actual: Positive	FN	TP

Confusion Matrix

ผลลัพธ์จริง (Actual)	การทำนาย (Predict)	ผลการทำนาย	Confusion Matrix
Negative	Negative	True	True Negative (TN)
Negative	Positive	False	False Positive (FP)
Positive	Negative	False	False Negative (FN)
Positive	Positive	True	True Positive (TP)

Confusion Matrix

x	y_true	y_predict	Confusion Matrix
…	1	1	TP
…	1	0	FN
…	0	0	TN
…	1	1	TP
…	1	0	FN
…	0	0	TN
…	1	1	TP
…	0	0	TN
…	0	1	FP
…	0	0	TN

Model Evaluation

	Predict (N)	Predict (P)	รวม
Actual (N)	TN = 20	FP = 10	30
Actual (P)	FN = 10	TP = 60	70
รวม	30	70	100

Model Evaluation

- **Accuracy** คือความแม่นยำในการทำนายผล โดยคิดจากจำนวนที่ทำนายถูกทั้งหมดหารด้วยจำนวนรายการทั้งหมดใน Confusion Matrix
- Accuracy = (20 + 60) / 100 = 0.8 หรืออัตราการทำนายถูกเท่ากับ 80%

$$\text{Accuracy} = \frac{TN + TP}{\text{Total}}$$

	Predict (N)	Predict (P)	รวม
Actual (N)	TN = 20	FP = 10	30
Actual (P)	FN = 10	TP = 60	70
รวม	30	70	100

Model Evaluation

- **Precision** คือ อัตราส่วนของการทำนายเชิงบวกแล้วถูกต้อง (TP) ต่อจำนวนการทำนายเชิงบวกทั้งหมด

Precision = 60 / 70 = 0.86

$$\text{Precision} = \frac{TP}{\text{Predict\_Positive}}$$

	Predict (N)	Predict (P)	รวม
Actual (N)	TN = 20	FP = 10	30
Actual (P)	FN = 10	TP = 60	70
รวม	30	70	100

Model Evaluation

- **Recall** (หรือ Sensitivity หรือ True Positive Rate) คือ ตราส่วนของการทำนายเชิงบวกแล้วถูกต้อง (TP) ต่อผลลัพธ์จริงในเชิงบวก (Actual Positive) ทั้งหมด

Recall = 60 / 70 = 0.86

$$\text{Recall} = \frac{TP}{Actual\_Positive}$$

	Predict (N)	Predict (P)	รวม
Actual (N)	TN = 20	FP = 10	30
Actual (P)	FN = 10	TP = 60	70
รวม	30	70	100

Model Evaluation

- **F1 Score** เป็นค่าที่แสดงถึงระดับความสอดคล้องกันระหว่าง Precision และ Recall

$$F1 = 2 * (0.86 * 0.86) / (0.86 + 0.86) = 0.86$$

$$F1 = \frac{2 * (precision * recall)}{precision + recall}$$

	Predict (N)	Predict (P)	รวม
Actual (N)	TN = 20	FP = 10	30
Actual (P)	FN = 10	TP = 60	70
รวม	30	70	100

Logistic Regression

- **Error Rate** (หรือ Misclassification Rate) คืออัตราความคลาดเคลื่อน ซึ่งคำนวณจากจำนวนที่ทำนายผิดทั้งหมด หารด้วยจำนวนรายการทั้งหมด
- จากจำนวนสมาชิกของ Confusion Matrix ที่ผ่านมา แสดงว่าอัตราความคลาดเคลื่อน คือ

err = (10 + 10) / 100 # 0.2 หรืออัตราทำนายผิดเท่ากับ 20%

$$\text{Error\_Rate} = \frac{FP + FN}{Total}$$

	Predict (N)	Predict (P)	รวม
Actual (N)	TN = 20	FP = 10	30
Actual (P)	FN = 10	TP = 60	70
รวม	30	70	100

Logistic Regression

- ค่าต่างๆ ดังที่กล่าวมา เราพิจารณาจากจำนวนที่ทำนายถูกต้องเป็นหลัก (ยกเว้น Error Rate) ดังนั้น ถ้าได้ตัวเลขที่มีค่ามากแสดงว่าจำนวนการทำนายผลถูกต้องก็มีมากเช่นกัน หรือกล่าวได้ว่า เป็นการทำนายผลมีความน่าเชื่อถือนั่นเอง

Logistic Regression

- บริษัทแห่งหนึ่งได้ทดสอบการทำงานของเครื่องจักรพบว่า อายุของเครื่องจักร (หน่วยเป็น เดือน) และจำนวนชั่วโมงการทำงานต่อวัน มีผลต่อสมรรถนะของเครื่องจักร ดังตารางไฟล์ machine_performance.xlsx ให้ทำนายผลในกรณีที่

1) อายุของเครื่องจักรเท่ากับ 20 เดือน และทำงาน 3 ชั่วโมงต่อวัน

2) อายุของเครื่องจักรเท่ากับ 50 เดือน และทำงาน 7 ชั่วโมงต่อวัน

3) อายุของเครื่องจักรเท่ากับ 40 เดือน และทำงาน 2 ชั่วโมงต่อวัน

4) อายุของเครื่องจักรเท่ากับ 80 เดือน และทำงาน 5 ชั่วโมงต่อวัน

และให้หา Logistic Function และ Confusion Matrix

	machine_age_months	work_hours_per_day	machine_performance
0	58	3	1
1	73	5	0
2	23	4	1
3	59	4	0
4	16	3	1
5	37	1	1
6	68	5	0
7	49	5	1
8	27	7	0
9	60	2	1
10	11	5	1
11	78	8	0
12	23	5	1
13	37	3	1
14	57	7	0
15	73	8	0
16	39	4	1
17	71	7	0
18	35	4	1
19	45	4	1

```
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

df = pd.read_excel(r'machine_performance.xlsx')
with pd.option_context('display.max_rows', 20): display(df)

x = df[['machine_age_months', 'work_hours_per_day']]
y = df['machine_performance']

x_train, x_test, y_train, y_test = train_test_split(x, y, random_state=0)

#scaling
scaler = StandardScaler()
x_train = scaler.fit_transform(x_train)
x_test = scaler.transform(x_test)

model = LogisticRegression()
model.fit(x_train, y_train)
```

```
x_pred = [[20, 3], [50, 7], [40, 2], [80, 5]]
#ข้อมูลที่จะทำนายผล ก็ต้องปรับสเกลเช่นเดียวกัน
x_pred_sc = scaler.transform(x_pred)
y_pred = model.predict(x_pred_sc)

print('Prediction:')
for (i, xp) in enumerate(x_pred):
    #คอลัมน์ผลสัพธ์มีค่าเป็น 0/1 จึงเทียบเป็นสตริงที่เข้าใจได้
    machine_perf = 'No' if y_pred[i] == 0 else 'Yes'
    text = f'Machine Age: {xp[0]} Month(s), '
    text += f'Work: {xp[1]} Hour(s)/Day '
    text += f'=> Performance: {machine_perf}'
    print(text)
print()

print('Logistic Function:')
ic = '{:.2f}'.format(model.intercept_[0])
ce1 = '{:.2f}'.format(model.coef_[0, 0])
ce2 = '{:.2f}'.format(model.coef_[0, 1])

print(f'P(x) = 1 / (1 + exp({ic} + ({ce1})age + ({ce2})hour))')
```

```
### Model Evaluation ####
y_pred_test = model.predict(x_test)
print('Confusion Matrix:')
cfmx = confusion_matrix(y_test, y_pred_test)
print(cfmx)
print()

print('Accuracy:', '{:.2f}'.format(accuracy_score(y_test, y_pred_test)))
print('Precision:', '{:.2f}'.format(precision_score(y_test, y_pred_test)))
print('Recall:', '{:.2f}'.format(recall_score(y_test, y_pred_test)))
print('F1 Score:', '{:.2f}'.format(f1_score(y_test, y_pred_test)))

#error_rate = (FP + FN) / Total
err = (cfmx[0, 1] + cfmx[1, 0]) / y_test.count()
print('Error Rate', '{:.2f}'.format(err))
print()
```

```
Prediction:
Machine Age: 30 Month(s), Work: 6 Hour(s)/Day => Performance: Yes
Machine Age: 40 Month(s), Work: 8 Hour(s)/Day => Performance: No
Machine Age: 50 Month(s), Work: 5 Hour(s)/Day => Performance: No
Machine Age: 60 Month(s), Work: 3 Hour(s)/Day => Performance: Yes

Logistic Function:
P(x) = 1 / (1 + exp(0.60 + (-1.21)age + (-1.10)hour))
Confusion Matrix:
[[1 1]
 [0 3]]

Accuracy: 0.80
Precision: 0.75
Recall: 1.00
F1 Score: 0.86
Error Rate 0.20
```